



Auto encoders (AEs)




$$\text{Error} = \|x - \hat{x}\| \rightarrow 0$$



¿O' significa?

Se ha comprimido la información de los datos de entrada similar a PCA. En este caso el procedimiento es no lineal.

Concepto de cuello de botella



Red profunda (diseñar y entrenar este tipo de red no es tan fácil)

Aplicar esto no es como PCA que ya tiene un procedimiento. Aquí hay que tener conocimiento de cómo funciona toda la arquitectura.

Entrada $x \in [0, 1]^d$

encoding $y \in [0, 1]^{d'}$ $d' \ll d$

decoding $z = g(w^*y + b)$

$w^* = w^T$ (compartición de pesos weight tying)


$$\text{El error } L(x, \hat{x}) = \|x - \hat{x}\|^2$$

Para entrada datos binarios la función de pérdida más adecuada es la entropía cruzada (Cross-entropy loss function)

$$L_H(x, \hat{x}) = \sum_{k=1}^d [x_k \log \hat{x}_k + (1-x_k) \log (1-\hat{x}_k)]$$

Problemas que aún persisten

- * Los métodos discriminativos Cosim y BP necesitan un tiempo largo de entrenamiento
- * BP puede quedar atrapado en




Inteligencia es entender los datos (no solo separar o discriminar datos).

Se lo entiende por regenerarlo

El conocimiento fundamental es usar datos.

Cuando ocurre un incendio forestal



Belief Network (bayesian)

- Espacio de probabilidades
- Modelación del sistema

* Ventajas

- Permite realizar ranking de los documentos
- Puede ser usado para representar el modelo booleano y vectorial
- Permite correspondencia parcial
- Permite realizar consultas a las consultas realizadas con anterioridad.


* Desventajas

- Asume independencia de los términos

Modelo de Potencia

Maquina de Boltzman

Este sería una red para simular un evento (el que sea)



- la maquina de Boltzman es una red neuronal estocástica (Probabilística) q busca encontrar patrones a los datos.


- la red funciona como un sistema q minimiza energía

- la función de energía está inspirada en la distribución de Boltzman de donde viene su nombre.

Idea: los estados de baja energía son más probables.

¿Q es restricción? $\equiv$ Simplificación

la restricción es uno de los herramientas más útiles que tenemos en ciencia de la computación



BH con interconexiones en toda las capas

RBM (frecuentemente son neuronas binarias)

$$RBM_{energy} : E(v, h) = -b^T v - c^T h - h^T w v \dots (1)$$


$b^T v$: bias de las neuronas visibles

$c^T h$: bias de las neuronas ocultas (hidden)

$h^T w v$: las neuronas visibles por los pesos de las neuronas.

v, h son binario
 $w \in [0, 1]$

para que pueda ocurrir la sinapsis.



Aprender significa asignar probabilidades a todos los posibles pares de visibles/hidden via la función de energía.

"Es aquí donde empezamos a formar patrones escribiendo la probabilidad"

Persona 1	1	0	0
Persona 2	0	1	1
Persona 3	1	1	1

de la ecuación (1) ignorando el bias.

$$P(\bar{v}, \bar{h}) = \frac{e^{-E(v, h)}}{Z}$$

función de partición

La probabilidad asignada al vector visible es:

$$P(\bar{v}) = \frac{1}{Z} \sum e^{-E(v, h)}$$


Lo usual es estimar valores es la forma práctica de lidiar con la función de partición

$$E(v, h) = - \sum_{i,j} v_i h_j w_{ij}$$

estados pesos
biases

Lo importante es las restricciones

- No hay conexiones entre neuronas visibles
- No hay conexiones entre neuronas ocultas
- independencia condicional.



Por lo tanto, se toman las consideraciones de que estoy ignorando el bias y la independencia condicional las probabilidades les.

¿Es posible? No es un proceso feed forward dado que estamos en un proceso recurrente de ir y volver por la red para ajustar los pesos. Por ahora no hay un dispositivo que nos permita realizar esto.

$$P(h|v) = \prod_j P(h_j|v)$$

$$P(v|h) = \prod_j P(v_j|h)$$

$$\frac{\partial \log P(v)}{\partial w_{ij}} = \langle v_i, h_j \rangle_{\text{entrenamiento}} - \langle v_i, h_j \rangle_{\text{modelo}}$$

Por ejemplo.

¿Cuál es la probabilidad de lluvia? 20%
¿Cuál es la probabilidad de malas noticias? 15%

$\langle -, - \rangle$: significa expectación bajo la distribución por el entrenamiento o el modelo.

$$\underbrace{E(V, h)}_{\text{error}} = - \sum v_p h_g w_{pg} \Rightarrow \frac{\partial E}{\partial w_{pg}} = v_p h_g$$

$$\Delta w_{pg} = \eta \left[\langle v_p, h_g \rangle^{(0)} - \langle v_p, h_g \rangle^{(\infty)} \right]$$

Donde:


$$h^{(n+1)} \approx g(w^T v^{(n)} + c)$$

$$v^{(n+1)} \approx \underbrace{g(w^T h^{(n)} + b)}_{\text{función de activación}}$$

El método de aprendizaje es el "contrastive Divergente" introducido por Hinton 2002

No es backpropagation

Asumiendo el criterio de las redes de las RBMs y regresando a los autoencoders.



- 1) exterior RBM "contrastive Divergente"
- 2) fine tuning con back propagation