

# Ejercicios Matemáticos para CNNs

Asuma que todos los tensores son de tipo flotante (float) y la función de activación utilizada es ReLU ( $\sigma(z) = \max(0, z)$ ).

## Bloque I: Operaciones Fundamentales (Convolución, Padding, Stride)

1. **Convolución 2D Manual (Stride 1, Padding 0):** Dado el tensor de entrada  $X$  (4x4) y el kernel  $W$  (3x3). Calcule el mapa de características de salida  $Y$ .

$$X = \begin{pmatrix} 1 & 0 & 2 & 1 \\ 0 & 3 & 0 & 2 \\ 1 & 1 & 0 & 1 \\ 2 & 0 & 1 & 0 \end{pmatrix}, \quad W = \begin{pmatrix} 1 & 0 & -1 \\ 0 & 1 & 0 \\ 1 & 0 & -1 \end{pmatrix}$$

2. **Cálculo de Dimensiones con Padding y Stride:** Un tensor de entrada  $X$  de  $28 \times 28 \times 1$  se procesa con una capa convolucional definida por:

- Kernel size ( $K$ ):  $5 \times 5$ .
- Stride ( $S$ ): 2.
- Padding ( $P$ ): 1. Calcule las dimensiones espaciales de salida ( $H_{out} \times W_{out}$ ).

3. **Cálculo de Parámetros y Bias (3D):** Una capa convolucional recibe una entrada de  $10 \times 10 \times 32$  (Canales  $C_{in} = 32$ ) y debe producir 64 mapas de características de salida ( $C_{out} = 64$ ). El kernel es de  $3 \times 3$ . Calcule el número total de parámetros **entrenables** (pesos  $W$  y bias  $b$ ).

## Bloque II: Downsampling y Operadores Lineales

4. **Max Pooling 2D Manual:** Dado el mapa de características  $Y$  (6x6). Aplique una operación de **Max Pooling** con un tamaño de ventana de  $2 \times 2$  y un *stride* de 2.

$$Y = \begin{pmatrix} 2 & 8 & 1 & 5 & 0 & 4 \\ 3 & 4 & 7 & 2 & 1 & 6 \\ 0 & 1 & 3 & 9 & 8 & 3 \\ 5 & 2 & 6 & 0 & 7 & 1 \\ 1 & 9 & 5 & 2 & 4 & 0 \\ 3 & 0 & 8 & 1 & 6 & 5 \end{pmatrix}$$

5. **Cálculo de Campo Receptivo (RF) Básico:** Una red tiene tres capas convolucionales consecutivas. Todas tienen *kernel size*  $3 \times 3$ , *stride* 1 y *padding* 0. Calcule el tamaño del **Campo Receptivo** (RF) efectivo de la salida de la tercera capa.
6. **Convolución con Dilatación (Atrous):** Dado un tensor de entrada  $X$  (5x5) y un kernel  $W$  (3x3). Calcule el resultado de la convolución usando un **factor de dilatación** ( $D$ ) de 2.

(Stride 1, Padding 0).

$$X = \begin{pmatrix} 1 & 1 & 1 & 1 & 1 \\ 1 & 2 & 2 & 2 & 1 \\ 1 & 2 & 3 & 2 & 1 \\ 1 & 2 & 2 & 2 & 1 \\ 1 & 1 & 1 & 1 & 1 \end{pmatrix}, \quad W = \begin{pmatrix} 1 & 0 & 1 \\ 0 & 1 & 0 \\ 1 & 0 & 1 \end{pmatrix}$$

7. **Cálculo de la Dimensión de Salida con Dilatación y Padding Asimétrico:** Una entrada  $X$  tiene dimensiones  $H \times W \times C_{in} = 40 \times 40 \times 16$ . Se aplica una capa convolucional con:
- Kernel size ( $K$ ):  $7 \times 7$ .
  - Stride ( $S$ ): 3.
  - Dilatación ( $D$ ): 2.
  - Padding Asimétrico:  $P_{top} = 1, P_{bottom} = 2, P_{left} = 3, P_{right} = 3$ . Calcule las dimensiones espaciales de salida exactas ( $H_{out} \times W_{out}$ ).
8. **Eficiencia Paramétrica (Factorización  $3 \times 3$  vs  $5 \times 5$ ):** Demuestre que una secuencia de dos kernels  $3 \times 3$  con  $C_{out}$  canales tiene, aproximadamente, un 28 menos de parámetros que un único kernel  $5 \times 5$  con el mismo número de canales  $C_{out}$ , mientras mantienen el mismo Campo Receptivo (RF) efectivo. Asuma  $C_{in} = C_{out} = C$ .
9. **Matrización 1D y Toeplitz (Ejercicio Conceptual):** Considere una convolución 1D  $Y = X * W$  con  $X = [x_1, x_2, x_3, x_4]$  y  $W = [w_1, w_2]$ . a) Escriba la matriz de Toeplitz  $\mathbf{T}_W$  que transforma la convolución en una multiplicación matricial  $y = \mathbf{T}_W x$ . b) Verifique que el producto  $\mathbf{T}_W^T \cdot \delta y$  (donde  $\delta y$  es el gradiente de salida) corresponde a la operación de **Convolución Transpuesta** (retropropagación a la entrada  $X$ ).

## Bloque III: Gradientes y Retropropagación Simplificada

10. **Gradiente de la Función de Activación ReLU:** Calcule  $\frac{d\sigma(z)}{dz}$  para los siguientes valores de entrada  $z$ :  $z_1 = 5, z_2 = 0, z_3 = -2$ .
11. **Cálculo Simplificado de Gradiente del Kernel ( $\frac{\partial L}{\partial W}$ ):** En una capa con *stride* 1 y *padding* 0, se observan los siguientes valores para una celda de salida:
- Entrada  $X$  (3x3): El patch de entrada activo es  $X_{patch} = \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix}$ .
  - Gradiente de la salida de la celda ( $\delta Y$ ):  $\delta y = -0.5$ .
  - Kernel  $W$  (2x2):  $W = \begin{pmatrix} w_{11} & w_{12} \\ w_{21} & w_{22} \end{pmatrix}$ . Calcule el valor del gradiente parcial  $\frac{\partial L}{\partial w_{22}}$  para la actualización del peso  $w_{22}$ .
12. **Retropropagación del Error a través de Max Pooling:** Dado un bloque de Max Pooling (2x2,  $S = 2$ ) y el gradiente de la capa siguiente  $\delta Y$  (2x2). Determine la matriz de

gradientes  $\delta X$  (4x4) que debe propagarse a la capa previa.

$$X = \begin{pmatrix} 1 & 5 & 2 & 3 \\ 0 & 4 & 1 & 6 \\ 7 & 8 & 3 & 9 \\ 2 & 1 & 0 & 5 \end{pmatrix}, \quad \delta Y = \begin{pmatrix} 0.2 & -0.1 \\ 0.5 & 0.3 \end{pmatrix}$$

13. **Análisis del Flujo de Gradientes en un Bloque Residual (Concepto Formal):** Considere un bloque residual definido por la función  $H(x) = \mathcal{F}(x) + x$ , donde  $\mathcal{F}(x)$  es una secuencia de capas convolucionales y  $x$  es la conexión de identidad. Demuestre formalmente que si la pérdida  $L$  depende de la salida  $H(x)$ , el gradiente  $\frac{\partial L}{\partial x}$  siempre contendrá un término igual al gradiente de la salida  $\frac{\partial L}{\partial H(x)}$ .

14. **Derivación Formal de la Retropropagación a través de la Activación:** Considere una pérdida  $L$ . Demuestre que el gradiente que entra a la capa lineal  $\mathbf{z}$  (antes de la activación) es:

$$\frac{\partial L}{\partial \mathbf{z}} = \frac{\partial L}{\partial \mathbf{a}} \odot \sigma'(\mathbf{z})$$

donde  $\mathbf{a} = \sigma(\mathbf{z})$  y  $\odot$  es el producto de Hadamard (producto elemento a elemento). Considere  $\sigma(\mathbf{z})$  como la función Sigmoid( $\mathbf{z}$ ).

15. **Análisis de Gradiente en Global Average Pooling (GAP):** El Global Average Pooling (GAP) opera sobre un mapa de características  $X \in \mathbb{R}^{H \times W \times C}$  para producir un vector  $Y \in \mathbb{R}^C$  donde  $Y_k = \frac{1}{HW} \sum_{i,j} X_{i,j,k}$ . Dado el gradiente de la pérdida respecto a la salida,  $\delta Y = \frac{\partial L}{\partial Y}$ . Derivación:

$$\frac{\partial L}{\partial X_{i,j,k}}$$

(Demostrar que el gradiente se distribuye uniformemente sobre el mapa de entrada).

16. **Flujo de Gradientes en el Max Pooling (Formal):** Defina la función del Max Pooling como  $y = \max_{i \in R} \{x_i\}$  donde  $R$  es la región de *pooling*. Formalice el gradiente  $\frac{\partial L}{\partial x_k}$  para un elemento  $x_k$  dentro de la región  $R$ , en función del gradiente de salida  $\frac{\partial L}{\partial y}$  y la **función indicador**  $I(\cdot)$  que identifica al "ganador".
17. **Derivación de la Pérdida L2 (Regularización de Pesos):** La función de pérdida total es  $J(\mathbf{W}) = L(\mathbf{W}) + \lambda \cdot R(\mathbf{W})$ , donde  $R(\mathbf{W}) = \frac{1}{2} \|\mathbf{W}\|_2^2$  es el término de regularización L2. Demuestre que el gradiente total,  $\frac{\partial J}{\partial \mathbf{W}}$ , introduce un término aditivo simple en la regla de actualización de pesos (conocido como **weight decay**).