



UNIVERSIDAD NACIONAL DE INGENIERÍA

Facultad de Ciencias

Escuela Profesional de Ciencias de la Computación

Examen Parcial

Curso: Inteligencia Artificial (CC421)

Semestre 2025-II (22/10/2025)

Instrucciones:

- Lea cuidadosamente cada pregunta antes de responder.
- Justifique todas sus respuestas con argumentos claros y concisos, haciendo referencia a los conceptos aprendidos en el curso.
- La claridad, el rigor conceptual y la profundidad del análisis serán valorados.
- Se prohíbe el uso de cualquier material no autorizado.

1. **La Convergencia de Razón, Propiedad y Compasión como Base para una Ética de la IA Robusta (3 pts):** La filosofía occidental ofrece bases éticas divergentes: razón y fe (Tomás de Aquino), propiedad/interés (Locke/Hobbes) y compasión/reducción del sufrimiento (Schopenhauer/Bentham). Dado que la IA debe interactuar con sistemas económicos (propiedad), tomar decisiones morales (razón), y potencialmente impactar a seres capaces de sufrir (Bentham), ¿cómo podría una **ética de la IA robusta** integrar la necesidad de la razón filosófica (siguiendo el ejemplo de Aquino de conciliar principios) con la importancia del contrato social/propiedad de Locke y la necesidad de minimizar el sufrimiento de Schopenhauer y Bentham, para crear un conjunto coherente de principios que trascienda un solo fundamento moral?

2. **El Sudoku Mínimo 2×2 (3 pts):** Considere una cuadrícula de 2×2 que debe llenarse con los números $\{1, 2\}$.

- **Variables:** $V_{i,j}$ (celda en la fila i , columna j), con $i, j \in \{1, 2\}$. Variables: $V_{1,1}, V_{1,2}, V_{2,1}, V_{2,2}$.
- **Dominio Inicial (D):** $\{1, 2\}$ para todas las variables.
- **Restricciones:** Los valores deben ser diferentes en la misma fila y en la misma columna.
- **Pre-asignación (Restricción de Borde):** $V_{1,1} = 2$.

Tarea: Encontrar la única solución aplicando Backtracking con Forward Checking. Usar la heurística de selección de variable **orden lexicográfico** y la heurística de ordenación de valores **orden ascendente** (1, 2).

3. **Planificación de Comidas Semanales con Alergias y Restricciones de Cocina (2 pts):** Una persona está planificando 3 comidas principales (Almuerzo L_1, L_2, L_3) para 3 días de la semana (Día 1, Día 2, Día 3). Cada día tendrá un único almuerzo diferente.

Tarea: Formalizar este problema como un CSP identificando:

- Variables: (¿Qué necesita asignarse?)
- Dominio: (¿Cuáles son los posibles valores?)
- Restricciones: (Definición precisa de las condiciones que deben cumplirse).

Condiciones del Mundo Real:

a) Disponibilidad de Ingredientes: La comida L_1 requiere un horno (solo disponible el Día 2).

- b) Variedad Diaria: El L_2 no puede ir en días consecutivos al L_1 (aunque solo tenemos 3 días, la restricción debe formalizarse para evitar adyacencia).
- c) Alergias: La comida L_3 contiene un alérgeno que debe evitarse el Día 3 por una reunión social.

4. Derivación del Gradiente en t-SNE: (3 pts)

La función de costo es la Divergencia de Kullback-Leibler, $C = D_{KL}(P||Q)$. Derive el gradiente de esta función de costo respecto a las coordenadas del punto proyectado $\mathbf{y}_i$.

$$\frac{\partial C}{\partial \mathbf{y}_i} = 4 \sum_{j \neq i} (p_{ij} - q_{ij}) (1 + \|\mathbf{y}_i - \mathbf{y}_j\|^2)^{-1} (\mathbf{y}_i - \mathbf{y}_j)$$

5. Evaluación de: PCA, LDA y t-SNE sobre Datos Mínimos (9 pts)

Suponga que se ha obtenido el siguiente conjunto de datos mínimo que consta de $n = 4$ observaciones y $D = 3$ variables (X_1, X_2, X_3). Las observaciones pertenecen a dos clases, $\mathcal{C}_1$ y $\mathcal{C}_2$.

Obs. (i)	X_1	X_2	X_3	Clase (y_i)
O_1	1	2	3	$\mathcal{C}_1$
O_2	3	4	5	$\mathcal{C}_1$
O_3	1	4	7	$\mathcal{C}_2$
O_4	3	2	9	$\mathcal{C}_2$

Cuadro 1: Tabla de observaciones con variables y clases

a) Análisis de Componentes Principales (2 pts)

1) Datos Centrados y Covarianza:

- Calcule el vector de medias $\bar{\mathbf{x}}$ de la matriz de datos $\mathbf{X}$.
- Calcule la matriz de datos centrada $\mathbf{Z} = \mathbf{X} - \mathbf{1}\bar{\mathbf{x}}^T$.
- Calcule la matriz de covarianza muestral $\mathbf{C} = \frac{1}{n-1} \mathbf{Z}^T \mathbf{Z}$. (Use el factor de normalización $n - 1 = 3$).

2) Autodescomposición:

- Calcule los autovalores $\lambda_1, \lambda_2, \lambda_3$ de $\mathbf{C}$.
- Determine el porcentaje de varianza explicado por cada componente principal.
- Discuta conceptualmente: ¿Qué implica para la estructura de los datos que dos de los autovalores sean cero o muy pequeños? ¿Qué información se pierde al reducir la dimensionalidad de 3 a 2?

b) Análisis Discriminante Lineal (3 pts)

1) Parámetros por Clase:

- Calcule los vectores de medias por clase: $\bar{\mathbf{x}}_{\mathcal{C}_1}$ y $\bar{\mathbf{x}}_{\mathcal{C}_2}$.
- Calcule la matriz de dispersión intra-clase $\mathbf{S}_W = \sum_{k=1}^2 \mathbf{S}_k$, donde $\mathbf{S}_k = \sum_{i \in \mathcal{C}_k} (\mathbf{x}_i - \bar{\mathbf{x}}_{\mathcal{C}_k})(\mathbf{x}_i - \bar{\mathbf{x}}_{\mathcal{C}_k})^T$.
- Justifique brevemente por qué $\mathbf{S}_W$ debe ser singular y cuál es el rango máximo de $\mathbf{S}_W$ en este caso particular.

2) Dirección Discriminante ($\mathbf{w}$):

- Calcule la matriz de dispersión entre-clases $\mathbf{S}_B = n_1(\bar{\mathbf{x}}_{\mathcal{C}_1} - \bar{\mathbf{x}})(\bar{\mathbf{x}}_{\mathcal{C}_1} - \bar{\mathbf{x}})^T + n_2(\bar{\mathbf{x}}_{\mathcal{C}_2} - \bar{\mathbf{x}})(\bar{\mathbf{x}}_{\mathcal{C}_2} - \bar{\mathbf{x}})^T$.
- Calcule el vector $\mathbf{w}$ que maximiza la separabilidad. Para dos clases y $\mathbf{S}_W$ no singular, $\mathbf{w} \propto \mathbf{S}_W^{-1}(\bar{\mathbf{x}}_{\mathcal{C}_1} - \bar{\mathbf{x}}_{\mathcal{C}_2})$. Dado que $\mathbf{S}_W$ es singular, utilice la simplificación $\mathbf{w} \propto (\bar{\mathbf{x}}_{\mathcal{C}_1} - \bar{\mathbf{x}}_{\mathcal{C}_2})$.

3) Proyección y Separabilidad:

- Proyecte los cuatro puntos $\mathbf{x}_i$ en la dirección $\mathbf{w}$: $z_i = \mathbf{w}^T \mathbf{x}_i$.
- Analice la separabilidad: proponga un umbral de clasificación T y determine si las clases son linealmente separables en esta nueva dimensión 1D.

c) **t-Distributed Stochastic Neighbor Embedding (t-SNE) (4 pts)**

1) Distancias en el Espacio Alto:

- Calcule la matriz de distancias euclídeas al cuadrado D_{ij}^2 entre las 4 observaciones $\mathbf{x}_i$.

2) Afinidades P (Alta Dimensionalidad):

- Utilice una σ tal que las afinidades $\text{Aff}(j|i) = \exp(-D_{ij}^2/(2\sigma^2))$ sean proporcionales a 1 para $j \neq i$. Suponga que todas las distancias D_{ij}^2 son suficientemente grandes. En el caso de que D_{ij}^2 sean idénticas para $j \neq i$: Explique por qué, si D_{ij}^2 son todas iguales para $j \neq i$, la matriz de afinidades simétricas $P_{ij} = \frac{\text{Aff}(j|i) + \text{Aff}(i|j)}{2n}$ (donde $\text{Aff}(j|i)$ es la matriz de afinidades de un punto a otro, y n el número de vecinos) se simplifica a una constante $P_{ij} = p_0$ para todo $i \neq j$.
- Calcule el valor numérico de P_{ij} para $i \neq j$, asumiendo que el término de afinidad simétrica es $P_{ij} = 0.05$ (para simplificar el cálculo).

3) Afinidades Q (Baja Dimensionalidad):

- Se propone una inicialización en 2D: $\mathbf{y}_1 = (1, 1)$, $\mathbf{y}_2 = (-1, -1)$, $\mathbf{y}_3 = (-1, 1)$, $\mathbf{y}_4 = (1, -1)$.
- Calcule la matriz de afinidades de baja dimensionalidad Q_{ij} usando el kernel de Student-t con $\nu = 1$ (i.e., $(1 + \|\mathbf{y}_i - \mathbf{y}_j\|^2)^{-1}$), y normalice para que $\sum_{i \neq j} Q_{ij} = 1$.

4) Evaluación de la Divergencia KL:

- Calcule el valor de la divergencia Kullback-Leibler (KL) entre P y Q : $\text{KL}(P||Q) = \sum_{i \neq j} P_{ij} \ln \left(\frac{P_{ij}}{Q_{ij}} \right)$. Use $\ln(0.05) \approx -3.00$ y $\ln(0.125) \approx -2.08$.