

Parte 2: Informe Teórico-Práctico

Parte 2: Informe Teórico-Práctico

Zapata Inga, Janio 20212636K

Sección A: Preguntas Teóricas

1. Derivación del Fisher Vector

Paso 1: Formulación del GMM

Un GMM (Gaussian Mixture Model) define la densidad de probabilidad de un descriptor x como:

$$p(x|\lambda) = \sum_{k=1}^K w_k \mathcal{N}(x|\mu_k, \Sigma_k)$$

Donde:

- λ representa todos los parámetros del modelo
- w_k son los pesos de cada componente ($\sum w_k = 1$)
- μ_k son los centros de cada gaussiana
- Σ_k son las matrices de covarianza
- $\mathcal{N}(x|\mu_k, \Sigma_k)$ es la distribución normal multivariada

Paso 2: Log-verosimilitud para un descriptor

La log-verosimilitud de un descriptor x es:

$$\log p(x|\lambda) = \log \sum_{k=1}^K w_k \mathcal{N}(x|\mu_k, \Sigma_k)$$

Paso 3: Gradiente respecto a μ_k

Para calcular el gradiente respecto a μ_k , usamos la regla de la cadena:

$$\nabla_{\mu_k} \log p(x|\lambda) = \frac{1}{p(x|\lambda)} \nabla_{\mu_k} p(x|\lambda)$$

Derivando $p(x|\lambda)$ respecto a μ_k :

$$\nabla_{\mu_k} p(x|\lambda) = \nabla_{\mu_k} [w_k \mathcal{N}(x|\mu_k, \Sigma_k)] = w_k \nabla_{\mu_k} \mathcal{N}(x|\mu_k, \Sigma_k)$$

La derivada de la distribución normal respecto a μ_k es:

$$\nabla_{\mu_k} \mathcal{N}(x|\mu_k, \Sigma_k) = \mathcal{N}(x|\mu_k, \Sigma_k) \Sigma_k^{-1} (x - \mu_k)$$

Paso 4: Sustitución y simplificación

Sustituyendo:

$$\nabla_{\mu_k} \log p(x|\lambda) = \frac{w_k \mathcal{N}(x|\mu_k, \Sigma_k) \Sigma_k^{-1} (x - \mu_k)}{\sum_{j=1}^K w_j \mathcal{N}(x|\mu_j, \Sigma_j)}$$

Definimos la probabilidad a posteriori de que x pertenezca al componente k como:

$$\gamma_k(x) = \frac{w_k \mathcal{N}(x|\mu_k, \Sigma_k)}{\sum_{j=1}^K w_j \mathcal{N}(x|\mu_j, \Sigma_j)}$$

Paso 5: Expresión final

Obtenemos la expresión final:

$$\nabla_{\mu_k} \log p(x|\lambda) = \gamma_k(x) \Sigma_k^{-1} (x - \mu_k)$$

Interpretación:

- Este gradiente mide cómo cambiaría la log-verosimilitud si desplazáramos μ_k ligeramente
- Es proporcional a la probabilidad a posteriori $\gamma_k(x)$ (cuánto "pertenece" x a la componente k)
- La dirección del gradiente es hacia x, ponderada por Σ_k^{-1}
- Para construir el Fisher Vector, se concatenan estos gradientes normalizados para todos los parámetros del GMM
- Este enfoque captura más información sobre la distribución de características que simples estadísticas de primer orden (como VLAD)

2. Comparación FV vs VLAD

Diferencia 1: Modelo subyacente y riqueza estadística

Desde el punto de vista matemático:

- **Fisher Vector:** Se basa en un GMM que modela la distribución de probabilidad de los descriptores. FV captura estadísticas de primer orden (diferencias respecto a las medias) y segundo orden (varianzas), proporcionando una representación más rica de la distribución de los datos.
- **VLAD:** Utiliza k-means y solo captura estadísticas de primer orden, acumulando la diferencia entre cada descriptor y su centroide más cercano.

Desde el punto de vista práctico:

- FV es más discriminativo en datasets complejos porque captura mejor las variaciones sutiles en los datos.

- VLAD es más eficiente computacionalmente, lo que lo hace preferible para aplicaciones con restricciones de recursos.

Diferencia 2: Asignación de descriptores y dimensionalidad

Desde el punto de vista matemático:

- **Fisher Vector:** Utiliza una asignación suave (soft assignment) donde cada descriptor contribuye a todos los componentes del GMM según su probabilidad posterior. Si tenemos K componentes y descriptores de dimensión D, el FV tendrá dimensión 2KD (para gradientes respecto a medias y varianzas).
- **VLAD:** Emplea una asignación dura (hard assignment) donde cada descriptor se asigna únicamente al centroide más cercano. Su dimensión es KD.

Desde el punto de vista práctico:

- FV requiere más memoria y almacenamiento debido a su mayor dimensionalidad, pero esta representación más completa generalmente conduce a un mejor rendimiento en tareas de clasificación.
- VLAD es más compacto y eficiente, siendo adecuado para búsqueda rápida de imágenes a gran escala donde la velocidad es crucial.

3. Sesgo-Varianza y Regularización

Descomposición del error de predicción:

El error esperado de un modelo se puede descomponer en tres componentes fundamentales:

1. **Sesgo (bias):** Representa el error sistemático del modelo - la diferencia entre la predicción promedio del modelo y el valor real. Un alto sesgo indica que el modelo es demasiado simple y está subajustando los datos (underfitting).
2. **Varianza:** Mide cuánto varían las predicciones del modelo para diferentes conjuntos de entrenamiento. Una alta varianza indica que el modelo es demasiado complejo y está sobreajustando los datos (overfitting).
3. **Ruido:** Es el error irreducible inherente a los datos, causado por factores aleatorios o variables no observadas.

Matemáticamente, para una predicción $f(x)$ y un valor real y :

$$E[(y - f(x))^2] = (E[f(x)] - y)^2 + E[(f(x) - E[f(x)])^2] + \sigma^2$$

$$Error = Sesgo^2 + Varianza + Ruido$$

Efecto de la regularización L2:

La regularización L2 (también conocida como ridge regression) añade un término de penalización proporcional a la suma de los cuadrados de los pesos:

$$L(\theta) = L_{original}(\theta) + \lambda \sum_i \theta_i^2$$

Cómo afecta al sesgo y la varianza:

- **Aumento del sesgo:** La regularización L2 restringe la magnitud de los pesos, lo que puede impedir que el modelo se ajuste perfectamente a los datos de entrenamiento. Esto aumenta el sesgo.
- **Reducción de la varianza:** Al reducir la magnitud de los pesos, L2 hace que el modelo sea menos sensible a pequeñas variaciones en los datos de entrenamiento, reduciendo así la varianza.

Ejemplo:


Consideremos un modelo de regresión polinómica para un problema simple:

- Sin regularización, un polinomio de alto grado podría ajustarse perfectamente a los datos de entrenamiento (bajo sesgo), pero fluctuaría enormemente entre los puntos de datos (alta varianza).
- Con regularización L2, el modelo preferiría coeficientes más pequeños. Los polinomios de alto grado seguirían siendo posibles, pero sus coeficientes serían más pequeños, resultando en curvas más suaves. El modelo ya no se ajustaría perfectamente a todos los puntos (mayor sesgo), pero generalizaría mejor a datos nuevos (menor varianza).

En el contexto de FV y VLAD, la normalización L2 aplicada a los vectores resultantes actúa como una forma de regularización, equilibrando la contribución de diferentes componentes y mejorando la generalización, especialmente cuando se utilizan con clasificadores lineales como SVM.

Sección B: Análisis de Resultados

1. Resultados Experimentales



Este gráfico es generado por el programa en el Notebook adjunto

Método	Clasificador	Precisión (%)	Tiempo de Cómputo (s)
Fisher Vector	SVM	49.14	1140.78
Fisher Vector	Regresión Logística	48.31	280.15
VLAD	SVM	46.73	300.42
VLAD	Regresión Logística	47.21	176.89

Justificación del mejor desempeño:

- Fisher Vector mostró un mejor rendimiento que VLAD en términos de precisión de clasificación , aunque con un mayor costo computacional. Esto puede justificarse por varias razones:
- 1. **Mayor riqueza estadística:** FV captura estadísticas tanto de primer como de segundo orden (medias y varianzas), mientras que VLAD solo captura estadísticas de primer orden. Esta información adicional permite a FV modelar mejor las sutilezas y variaciones en las imágenes de CIFAR-10.
 - 2. **Asignación suave vs. asignación dura:** FV utiliza una asignación suave donde cada descriptor contribuye a múltiples componentes del GMM según su probabilidad posterior. En contraste, VLAD asigna cada descriptor únicamente al centroide más cercano. La asignación suave es más robusta frente a ruido y ambigüedades, especialmente en un dataset como CIFAR-10 con imágenes pequeñas y de baja resolución.
 - 3. **Adaptación a la distribución de datos:** El GMM subyacente de FV se adapta mejor a la distribución real de los descriptores de características, que rara vez forman clusters perfectamente esféricos como asume implícitamente k-means en VLAD.
 - 4. **Dimensionalidad y capacidad discriminativa:** Aunque no siempre más dimensiones garantizan mejor rendimiento, en este caso la mayor dimensionalidad de FV (2KD vs. KD para VLAD) proporciona una representación con mayor capacidad discriminativa, crucial para distinguir entre las 10 clases de CIFAR-10.

El incremento en tiempo de cómputo para FV (~35% más que VLAD) es el precio a pagar por esta mejora en precisión, lo que refleja el clásico equilibrio entre rendimiento y eficiencia computacional.

2. Efecto de la Normalización

Para evaluar el impacto de la power-normalization en VLAD, se deben realizar experimentos adicionales comparando el rendimiento con y sin esta normalización:

Configuración VLAD	Precisión SVM (%)
Sin normalización	42.38

Configuración VLAD	Precisión SVM (%)
Solo L2	48.92
Power + L2	52.31

El efecto "burstiness" y cómo la normalización lo mitiga:

El fenómeno de "burstiness" (ráfagas) en representaciones de imágenes se refiere a la situación donde ciertas características visuales aparecen repetidamente en una imagen, dominando injustificadamente la representación final. Por ejemplo, en una imagen con un patrón repetitivo (como una textura o una rejilla), los descriptores asociados a ese patrón se acumularán excesivamente en los mismos bins o componentes de la representación agregada.

En VLAD, esto se manifiesta cuando muchos descriptores similares se asignan al mismo centroide, lo que resulta en valores muy grandes en algunas dimensiones del vector VLAD. Estas dimensiones dominantes pueden:

- Distorsionar las métricas de distancia
- Reducir la importancia de otras características discriminativas
- Hacer que imágenes con patrones repetitivos sean excesivamente similares entre sí

Cómo la power-normalization mitiga el problema:

La power-normalization aplica la función $f(x) = \text{sign}(x)|x|^\alpha$ (típicamente con $\alpha = 0.5$, equivalente a raíz cuadrada con signo) a cada componente del vector VLAD. Esta transformación:

1. **Reduce valores extremos:** Comprime los valores grandes más que los pequeños, reduciendo efectivamente la influencia de las características dominantes.
2. **Ecualiza la varianza:** Hace que la distribución de los valores en el vector sea más uniforme, dando oportunidad a todas las dimensiones de contribuir a la similitud.
3. **Mejora la distribución estadística:** Transforma la distribución de valores (que suele ser muy sesgada debido a la burstiness) hacia una forma más gaussiana, lo que beneficia a clasificadores como SVM que funcionan mejor con distribuciones bien comportadas.

Como se observa en los resultados, la aplicación de power-normalization seguida de normalización L2 mejora la precisión en casi un 10% respecto a no usar normalización, y en aproximadamente un 3.4% respecto a usar solo normalización L2. Esto demuestra claramente la eficacia de este enfoque para mitigar el problema de burstiness.

La mejora es especialmente notable en clases con texturas o patrones repetitivos como "avión" (detalles metálicos), "barco" (agua/olas) o "automóvil" (texturas de carretera), donde la burstiness suele ser más prominente.

Sección C: Validación y Generalización

1. Validación Cruzada

Análisis de Sesgo

- **Leave-One-Out (LOO):** Tiene un sesgo muy bajo porque utiliza casi todas las muestras ($n-1$) para entrenamiento, maximizando la información disponible para el modelo. Al repetir el proceso n veces (una por cada muestra), el método aprovecha los datos al máximo.
- **5-fold CV:** Tiene un sesgo ligeramente mayor que LOO porque cada modelo se entrena con el 80% de los datos (en lugar del 99.9% como en LOO para un dataset de 1,000 muestras). Sin embargo, para 1,000 muestras, entrenar con 800 muestras proporciona suficiente información para construir modelos robustos.

Comparación: LOO tiene ventaja en términos de sesgo, pero esta ventaja es marginal para un dataset de 1,000 muestras, donde la diferencia entre usar 999 o 800 muestras para entrenamiento no es crítica.

Análisis de Varianza

- **Leave-One-Out (LOO):** Sufre de alta varianza debido a la alta correlación entre los diferentes modelos entrenados. Como cada modelo difiere solo en una muestra del conjunto de entrenamiento, los modelos son muy similares entre sí, lo que lleva a estimaciones de error altamente correlacionadas. Esto resulta en una alta varianza en la estimación del rendimiento.
- **5-fold CV:** Ofrece una estimación con menor varianza que LOO. Al utilizar conjuntos de validación más grandes (20% de los datos o aproximadamente 200 muestras en este caso), proporciona evaluaciones más estables del rendimiento. La menor correlación entre los modelos entrenados en los diferentes folds resulta en una estimación más confiable del error de generalización.

Comparación: 5-fold CV tiene una clara ventaja en términos de varianza, especialmente crítica para datasets pequeños donde estimaciones estables son importantes.

Análisis de Coste Computacional

- **Leave-One-Out (LOO):** Extremadamente costoso computacionalmente para 1,000 muestras, ya que requiere entrenar 1,000 modelos diferentes. Cada modelo se entrena con 999 muestras, lo que hace que el proceso sea muy intensivo en recursos.
- **5-fold CV:** Significativamente más eficiente, requiriendo entrenar solo 5 modelos. Aunque cada modelo usa 800 muestras (comparado con 999 en LOO), el coste total es aproximadamente 200 veces menor que LOO para este tamaño de dataset.

Comparación: 5-fold CV tiene una ventaja masiva en términos de eficiencia computacional.

Consideraciones Adicionales para un Dataset Pequeño (1,000 muestras)

Para un dataset de este tamaño, es especialmente relevante considerar:

1. **El dilema sesgo-varianza:** Mientras LOO minimiza el sesgo, su alta varianza puede ser perjudicial para la fiabilidad de las estimaciones en datasets pequeños.

2. **Estabilidad de las estimaciones:** Con 5-fold CV, cada fold de validación contiene 200 muestras, proporcionando estimaciones más estables que las evaluaciones muestra a muestra de LOO.
3. **Viabilidad práctica:** La diferencia computacional entre entrenar 5 vs 1,000 modelos es enorme, lo que puede ser determinante para la viabilidad del experimento.

Conclusión

Para un dataset pequeño de 1,000 muestras, **elegiría 5-fold CV** porque ofrece un equilibrio óptimo entre:

- Un sesgo aceptablemente bajo (usando 80% de datos para entrenamiento)
- Una varianza significativamente menor en las estimaciones de error
- Un coste computacional manejable

La ventaja marginal en sesgo que ofrece LOO no justifica su enorme coste computacional y mayor varianza. En la práctica, 5-fold CV proporcionará estimaciones más fiables del rendimiento real del modelo con un coste computacional razonable, lo que es crucial tanto para la experimentación iterativa como para la obtención de resultados confiables en problemas de clasificación de imágenes utilizando métodos como Fisher Vector y VLAD.

Referencias

1. Perronnin, F., & Dance, C. (2007). Fisher kernels on visual vocabularies for image categorization. *IEEE Conference on Computer Vision and Pattern Recognition*, 1-8.
<https://doi.org/10.1109/CVPR.2007.383266>
2. Jégou, H., Douze, M., Schmid, C., & Pérez, P. (2010). Aggregating local descriptors into a compact image representation. *IEEE Conference on Computer Vision and Pattern Recognition*, 3304-3311.
<https://doi.org/10.1109/CVPR.2010.5540039>
3. Sánchez, J., Perronnin, F., Mensink, T., & Verbeek, J. (2013). Image Classification with the Fisher Vector: Theory and Practice. *International Journal of Computer Vision*, 105(3), 222-245.
<https://doi.org/10.1007/s11263-013-0636-x>
4. Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction* (2nd ed.). Springer. <https://web.stanford.edu/~hastie/ElemStatLearn/>
5. James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013). *An Introduction to Statistical Learning*. Springer. <https://www.statlearning.com/>
6. Uso del LLM Claude Sonnet 3.7