

Estudio Comparativo de Estrategias de Entrenamiento en Redes Neuronales Convolucionales

- Chowdury Junal
- La Torre Andre
- Mora Fernando
- Osorio Diego
- Zapata Janio



1. Introducción e Hipótesis

1.1 Contexto

Revolución Visual

Las Redes Neuronales Convolucionales (CNN) han transformado diferentes industrias, logrando diagnósticos de precisión sobrehumana.

El Costo Oculto

Estos modelos exigen millones de datos etiquetados. Una barrera infranqueable para startups y universidades con recursos limitados.

El Problema


¿Cómo innovar cuando la recolección masiva de datos es inviable?




1.2 Planteamiento del Problema

Transfer Learning: ¿De Dígitos a Formas?

- > **Overfitting (Sobreajuste):**
Con pocos datos, la red "memoriza" en lugar de aprender. Es ineficaz ante nuevos ejemplos.
- > **La Solución Propuesta:**
[Transfer Learning](#). Reutilizar el conocimiento visual previo de un dominio para resolver otro.
- > **El Desafío Experimental:**
¿Puede una red entrenada en MNIST (Dígitos) ayudar a clasificar Figuras Geométricas?
- > **La Lógica:**
Los "primitivos visuales" (bordes, curvas, esquinas) son universales.



1.3 Objetivos del Proyecto



1. Construcción

Creación de un dataset propio de 8 clases de figuras geométricas utilizando herramientas de dibujo digital desarrolladas a medida.



2. Experimentación

Implementación de tres escenarios controlados: Escasez de datos, Transfer Learning (MNIST), y Abundancia de datos.




3. Evaluación

Análisis cuantitativo de métricas clave (Accuracy, Loss) y estudio de patrones de error mediante matrices de confusión.

1.4 Hipótesis

Predicción del Rendimiento de los Modelos





$\text{Rendimiento}(C) < \text{Rendimiento}(A) < \text{Rendimiento}(B)$


Se espera que el conocimiento previo compense la falta de datos.

Marco Teórico



1. Convolutional Neural Networks



Convolution layer (CONV)




Agrupación (POOL)


Tipo	Agrupación máxima	Agrupación promedio
Objetivo	Cada operación de agrupación selecciona el valor máximo de la vista actual	Cada operación de agrupación promedia los valores de la vista actual
Ilustración		

Transfer Learning

Traditional Machine Learning



Transfer learning



Metricas de evaluacion

Accuracy (Exactitud): Proporción total de predicciones correctas.


$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}$$

Metodología


Construcción del dataset

- Volumen: 2027 imágenes
- Clases: Círculo, Cuadrado, Equis, Estrella, Rectángulo, Rombo, Semicírculo, Triángulo.
- Preprocesamiento: las imágenes serán redimensionadas a 28x28 píxeles y se normalizarán en un rango de (0,1) dividiendo por 255



MNIST: dataset fuente

- Volumen: 60 000 imágenes de entrenamiento y 10 000 de prueba
- Clases: Dígitos del 0 al 9
- Obliga a la red a aprender filtros de detección de trazos similares a los necesarios para las figuras geométricas




Escenarios experimentales

Escenario 1: Escasez de Datos (Red C)

- Entrenamiento desde cero.
- Se utilizó únicamente el 30 % del training set.

Escenario 2: Transfer Learning (Red A)



- Pre-entrenamiento en MNIST.
- Proceso:
 - Red base entrenada con MNIST
 - Congelamiento de las capas convolucionales
 - Reemplazo de la capa densa
 - Reentrenamiento del modelo



Escenario 3: Abundancia de Datos (Red B)

- Entrenamiento desde cero
- Se utilizó el 100 % del training set.


Arquitecturas de CNN




RED A

First -Phase of Training Red A with MNIST dataset

MNIST Dataset




Pre-training on MNIST



Phase 1: The model learns to **extract features** (edges, curves) by training on the **large MNIST dataset** of handwritten digits.

RED A


Phase 2 – Transfer Learning and Fine-Tuning Phase



Phase 2: The pre-trained 'eyes' are frozen. The 'brain' is kept trainable, and a new final layer is added to be fine-tuned on the 8-shape dataset.


RED B

Red B Architecture (Trained from Scratch for 8 Shapes)



RED C

Training Red C (Trained from Scratch with 30% of 8 Dataset)




Phase 3: The model is trained from scratch using only a small subset (30%) of the custom 8-shape dataset for 50 epochs.


RESULTADOS Y CONCLUSIONES

Comparación de Curvas de Aprendizaje

Comparación de Accuracy (Validación)



Comparación de Loss (Validación)



=====				
REPORTE DE CLASIFICACIÓN - RED A (Transfer MNIST)				
=====				
	precision	recall	f1-score	support
circulo	0.82	0.75	0.78	60
cuadrado	0.53	0.90	0.67	48
equis	0.78	0.86	0.82	88
estrella	1.00	0.95	0.98	42
rectangulo	1.00	0.69	0.82	42
rombo	0.83	0.54	0.65	28
semicirculo	0.88	0.76	0.81	37
triangulo	0.81	0.72	0.77	61
accuracy			0.79	406
macro avg	0.83	0.77	0.79	406
weighted avg	0.82	0.79	0.79	406



=====				
REPORTE DE CLASIFICACIÓN - RED C (Escasez - 30%)				
=====				
	precision	recall	f1-score	support
circulo	0.59	0.78	0.68	60
cuadrado	0.49	0.50	0.49	48
equis	0.79	0.80	0.79	88
estrella	0.95	0.88	0.91	42
rectangulo	1.00	0.64	0.78	42
rombo	0.72	0.46	0.57	28
semicirculo	0.71	0.73	0.72	37
triangulo	0.66	0.72	0.69	61
accuracy			0.71	406
macro avg	0.74	0.69	0.70	406
weighted avg	0.73	0.71	0.71	406




=====				
REPORTE DE CLASIFICACIÓN - RED B (Abundancia - 100%)				
=====				
	precision	recall	f1-score	support
circulo	0.77	0.88	0.82	60
cuadrado	0.71	0.92	0.80	48
equis	0.90	0.85	0.88	88
estrella	1.00	0.95	0.98	42
rectangulo	0.91	0.76	0.83	42
rombo	0.83	0.71	0.77	28
semicirculo	0.81	0.78	0.79	37
triangulo	0.88	0.82	0.85	61
accuracy			0.84	406
macro avg	0.85	0.84	0.84	406
weighted avg	0.85	0.84	0.85	406



Matrices de Confusión


Red C (30% Data)

Acc: 71.18%




Red A (Transfer)

Acc: 78.82%




Red B (100% Data)

Acc: 84.48%




Prueba Unitaria


IMAGEN REAL
id:194 | Label: rectangulo (4)



/usr/local/lib/python3.12/dist-packages/IPython/core/pylabtools.py:151: UserWarning: Glyph 9989 (\N{WHITE HEAVY CHECK MARK})
fig.canvas.print_figure(bytes_io, **kw)



/usr/local/lib/python3.12/dist-packages/IPython/core/pylabtools.py:151: UserWarning: Glyph 9989 (\N{WHITE HEAVY CHECK MARK})
fig.canvas.print_figure(bytes_io, **kw)



Conclusiones

Hipótesis Confirmada:

- Los datos respaldan

$\text{Rendimiento}(C) < \text{Rendimiento}(A) < \text{Rendimiento}(B)$

Impacto de la Escasez:

- Con el 30% de los datos (Red C), la red sufre de confusión morfológica (confunde cuadrados con rectángulos) y alta incertidumbre (Loss alto).

Valor del Transfer Learning:

- Usar MNIST (Red A) rescató casi un 8% de accuracy y mejoró drásticamente la detección de formas con trazos cruzados (como la "Equis"), demostrando que los filtros de dígitos son reutilizables.

Supremacía de los Datos:

- Nada supera tener el dataset completo (Red B), especialmente para distinguir formas difíciles como el "Rombo", donde se requiere mucha variedad de ejemplos para generalizar.

