

PD: Ejercicios de Reducción de Dimensionalidad (LDA y t-SNE)

Introducción y Notación

Este cuaderno contiene los 14 ejercicios asignados para la unidad de Reducción de Dimensionalidad. Las Etapas 1 y 2 son ejercicios teóricos/prácticos que deben resolverse en papel o en un documento separado. La Etapa 3 son ejercicios de programación que deben ejecutarse en este entorno.

Elemento	Símbolo	Descripción
Vector	$\mathbf{x}$	Letra minúscula en negrita (ej. vector de características).
Matriz	A	Letra mayúscula sin negrita (ej. matriz de datos).
Transposición	A^T	Transposición de la matriz A o vector $\mathbf{x}$.
Media Global	μ	Vector de media de todas las muestras.
Matriz Intraclase	S_W	Matriz de dispersión <i>dentro</i> de las clases.
Matriz Entreclases	S_B	Matriz de dispersión <i>entre</i> las clases.

Etapa 1: Comprensión Teórica y Demostración Matemática (6 Problemas)

Problemas de Linear Discriminant Analysis (LDA)

Pregunta 1: Derivación de S_W y S_B (Dificultad: Alta)

Demuestre cómo se definen y relacionan las matrices de dispersión intraclase (S_W) y entreclases (S_B) a partir de las medias de clase (μ_k) y la media global (μ), probando que la matriz de dispersión total S_T se descompone como:

$$S_T = S_W + S_B$$

Pregunta 2: Razón de Rayleigh (Dificultad: Media)

Partiendo de las definiciones de S_W y S_B , demuestre que la optimización de LDA es equivalente a encontrar la dirección $\mathbf{w}$ que maximiza la razón de Rayleigh de Fisher:

$$J(\mathbf{w}) = \frac{\mathbf{w}^T S_B \mathbf{w}}{\mathbf{w}^T S_W \mathbf{w}}$$

Pregunta 3: Sistema de Autovalores Generalizado (Dificultad: Alta)

Demuestre que, para encontrar el vector de proyección óptimo $\mathbf{w}$ que maximiza $J(\mathbf{w})$, el problema se reduce a resolver el sistema de autovalores generalizado:

$$S_B \mathbf{w} = \lambda S_W \mathbf{w}$$

Indicio: Use la derivada de la razón de Rayleigh respecto a $\mathbf{w}$ e iguálela a cero.

Problemas de t-distributed Stochastic Neighbor Embedding (t-SNE)

Pregunta 4: Similitudes en Alta Dimensión (Dificultad: Media)

Defina la probabilidad condicional de similitud en alta dimensión ($p_{j|i}$) utilizando el kernel Gaussiano. Luego, demuestre cómo se llega a la distribución de probabilidad conjunta simétrica p_{ij} .

$$p_{j|i} = \frac{\exp(-\|\mathbf{x}_i - \mathbf{x}_j\|^2 / 2\sigma_i^2)}{\sum_{k \neq i} \exp(-\|\mathbf{x}_i - \mathbf{x}_k\|^2 / 2\sigma_i^2)}$$

Pregunta 5: Kernel de Cauchy y *Crowding Problem* (Dificultad: Alta)

Demuestre la fórmula de la probabilidad de similitud en baja dimensión q_{ij} y explique la razón matemática por la cual t-SNE utiliza una **distribución t de Student con un grado de libertad** (kernel de Cauchy) en lugar de una Gaussiana para mitigar el *crowding problem*.

$$q_{ij} = \frac{(1 + \|\mathbf{y}_i - \mathbf{y}_j\|^2)^{-1}}{\sum_{k \neq l} (1 + \|\mathbf{y}_k - \mathbf{y}_l\|^2)^{-1}}$$

Pregunta 6: Derivación del Gradiente (Dificultad: Alta)

La función de costo es la Divergencia de Kullback-Leibler, $C = D_{KL}(P||Q)$. Derive el gradiente de esta función de costo respecto a las coordenadas del punto proyectado $\mathbf{y}_i$.

$$\frac{\partial C}{\partial \mathbf{y}_i} = 4 \sum_{j \neq i} (p_{ij} - q_{ij}) (1 + \|\mathbf{y}_i - \mathbf{y}_j\|^2)^{-1} (\mathbf{y}_i - \mathbf{y}_j)$$

Etapas 2: Ejercicios Prácticos en Papel (6 Problemas)

Problemas de Linear Discriminant Analysis (LDA)

Pregunta 7: Cálculo Manual de Dispersión (Dificultad: Media)

Dado el dataset 2D con dos clases:

$$C_1 = \{[1, 2]^T, [2, 3]^T\} \quad \text{y} \quad C_2 = \{[4, 4]^T, [5, 5]^T\}$$

Calcule: a) Las medias de clase μ_1 , μ_2 y la media global μ . b) Las matrices de dispersión intraclase S_W y entreclases S_B .

Pregunta 8: Proyección y Clasificación (Dificultad: Alta)

Utilizando los resultados de LDA-P1, determine el vector de proyección óptimo $\mathbf{w}$ (normalizado), asumiendo que es paralelo a $\mu_2 - \mu_1$. Calcule los puntos proyectados $z_i = \mathbf{w}^T \mathbf{x}_i$ y comente sobre la separabilidad de las clases en 1D.

Pregunta 9: Interpretación de Autovalores (Dificultad: Media)

En un problema con $C = 3$ clases y $D = 5$ dimensiones, se obtienen los siguientes autovalores de $S_W^{-1} S_B$: $\lambda_1 = 25.4$, $\lambda_2 = 8.1$, $\lambda_3 = 0.001$, $\lambda_4 = 10^{-8}$, $\lambda_5 = 0$. Interprete este resultado en

términos de: a) La dimensionalidad óptima de reducción. b) La importancia relativa de cada eje discriminante.

Problemas de t-distributed Stochastic Neighbor Embedding (t-SNE)

Pregunta 10: Probabilidades Condicionales (Dificultad: Media)

Considere 3 puntos en 2D: $\mathbf{x}_1 = [0, 0]^T$, $\mathbf{x}_2 = [1, 0]^T$, $\mathbf{x}_3 = [10, 10]^T$. Asumiendo una $\sigma_i = 1$ constante para todos los puntos (simplificación didáctica), calcule las probabilidades condicionales $p_{2|1}$ y $p_{3|1}$. Discuta el impacto de la distancia en la probabilidad de vecindad.

Pregunta 11: Efecto de *Perplexity* (Dificultad: Media)

Se aplica t-SNE a un dataset. En el ensayo A se usa `perplexity = 5` y en el ensayo B se usa `perplexity = 80`. Razone y explique el efecto esperado de cada parámetro en el gráfico resultante, centrándose en el balance entre la preservación de la estructura local y la global.

Pregunta 12: Fuerzas de Gradiente (Dificultad: Media)

En un proceso de optimización t-SNE, para un par de puntos $(\mathbf{x}_i, \mathbf{x}_j)$, se tiene una similitud alta en alta dimensión ($p_{ij} = 0.8$) y una similitud muy baja en baja dimensión ($q_{ij} = 0.01$). Usando la fórmula del gradiente (t-SNE-T6), discuta si el gradiente aplicará una fuerza de atracción o repulsión entre $\mathbf{y}_i$ y $\mathbf{y}_j$, y por qué.

Etapas 3: Programación en Python para Google Colab (2 Problemas)

Pregunta 13: LDA y Clasificación con Dataset Wine

Implemente un *pipeline* que aplique LDA para reducir el espacio de 13D a 2D en el dataset *Wine*. Visualice la proyección de las clases y evalúe la clasificación usando Regresión Logística en el espacio reducido.

Pregunta 14: t-SNE para Visualización con Dataset MNIST

Use un subconjunto de 5000 muestras del dataset *MNIST*. Aplique t-SNE para reducir la dimensionalidad de 784D a 2D. Visualice los resultados. Experimente y grafique el resultado con `perplexity = 10` y `perplexity = 50` para comparar el efecto del parámetro.