

Convenciones y Notación

A lo largo del material, utilizaremos la siguiente notación para mantener la claridad y el rigor matemático:

Notación	Descripción
$\mathbf{x}$	Vector (en negrita minúscula).
A	Matriz (en mayúscula).
A^T	Transpuesta de la matriz A .
$\bar{\mathbf{x}}$	Vector de medias de las características.
X	Matriz de datos originales (observaciones por filas, características por columnas).
$\tilde{X}$	Matriz de datos centrados (media restada).
$\text{Cov}(X)$	Matriz de Covarianza muestral.
$\mathbf{u}$	Autovector (vector propio).
λ	Autovalor (valor propio).
σ	Valor singular.
$\mathbf{1}$	Vector columna de unos.

Ecuaciones Fundamentales Numeradas

Definiremos las ecuaciones clave de PCA para su referencia en los ejercicios y el solucionario.

Matriz de Covarianza Muestral de Datos Centrados ($\tilde{X}$):

$$C = \text{Cov}(\tilde{X}) = \frac{1}{M-1} \tilde{X}^T \tilde{X} \quad (1)$$

(Donde M es el número de observaciones. En la práctica de ML, a menudo se usa M o $M-1$).

Problema de Autovalores y Autovectores:

$$C\mathbf{u} = \lambda\mathbf{u} \quad (2)$$

Varianza Proyectada (Función Objetivo de PCA): La varianza de los datos proyectados sobre un vector unitario $\mathbf{u}$ es:

$$\text{Var}(\mathbf{u}^T \tilde{X}) = \mathbf{u}^T C \mathbf{u} \quad (3)$$

Lagrangiano para la Maximización de la Varianza: Sujeto a la restricción de que el vector $\mathbf{u}$ sea unitario ($\mathbf{u}^T \mathbf{u} = 1$):

$$\mathcal{L}(\mathbf{u}, \lambda) = \mathbf{u}^T C \mathbf{u} - \lambda(\mathbf{u}^T \mathbf{u} - 1) \quad (4)$$

Descomposición en Valores Singulares (SVD) de la Matriz de Datos Centrada:

$$\tilde{X} = U \Sigma V^T \quad (5)$$

Donde las columnas de V son los autovectores de $\tilde{X}^T \tilde{X}$, que están directamente relacionados con los componentes principales de C .



Relación entre Autovalores (λ) y Valores Singulares (σ):

$$\lambda_i = \frac{\sigma_i^2}{M-1} \quad (6)$$

Error de Reconstrucción (minimización de la norma Frobenius): El error al reconstruir $\tilde{X}$ desde sus k componentes principales (columnas de V_k) es:

$$\text{Error}_{\text{reconstrucción}} = \|\tilde{X} - \tilde{X}V_kV_k^T\|_F^2 \quad (7)$$

Recursos y Datasets para Programación

Utilizaremos la librería `scikit-learn` para el acceso a datasets estándar y la implementación de PCA.

Dataset	Uso	Función de Carga (Python)
Wine	Problema Práctico 1 (Medio)	<code>sklearn.datasets.load_wine()</code>
MNIST-784	Problema Práctico 2 (Escalado)	<code>sklearn.datasets.fetch_openml('mnist_784', version=)</code>
Numpy/Pandas	Operaciones matriciales, preprocesamiento.	<code>import numpy as np</code> , <code>import pandas as pd</code>
Matplotlib/Seaborn	Visualización de componentes.	<code>import matplotlib.pyplot as plt</code> , <code>import seaborn as</code>

Ejercicios (12 Problemas) Sobre PCA

Parte 1 – Comprensión Teórica (5 problemas)

Pregunta 1

Derivación (Máxima Varianza): Demuestre que el problema de encontrar el vector unitario $\mathbf{u}$ que maximiza la varianza proyectada $\text{Var}(\mathbf{u}^T \tilde{X})$ se reduce al problema de autovalores de la matriz de covarianza.

- Use la herramienta de los Multiplicadores de Lagrange.
- Use las ecuaciones (3), (4), (2)

Pregunta 2

Equivalencia PCA $\Leftrightarrow$ Descomposición: Demuestre rigurosamente que si $\mathbf{u}_i$ es un autovector de la matriz de covarianza C (es decir, un componente principal), entonces $C\mathbf{u}_i = \lambda_i \mathbf{u}_i$, y los autovectores correspondientes a autovalores distintos son ortogonales.

- Recuerde que C es simétrica. Use la definición del producto interno.
- Use la ecuación (2)

Pregunta 3

Relación PCA $\Leftrightarrow$ SVD: Dada la SVD de la matriz de datos centrada $\tilde{X} = U\Sigma V^T$, deduzca por qué las columnas de V son los componentes principales y los valores singulares σ_i determinan la varianza explicada λ_i .

- Sustituya la SVD en la fórmula de la covarianza C (1) y use la definición de autovalor.
- Use las ecuaciones (1), (5), (6).

Pregunta 4

Minimización del Error de Reconstrucción: Demuestre que la proyección de los datos sobre los k autovectores de mayor autovalor de C (los k componentes principales) es la proyección que minimiza el error de reconstrucción en la norma Frobenius.

- Conecte el error con la suma de los autovalores no utilizados (los que se descartan).
- Use la ecuación (7)

Pregunta 5

Propiedades: Escalado y Rotación: a) Demuestre que si un conjunto de datos se rota ($\tilde{X}' = \tilde{X}R$, con R ortogonal), la varianza total ($\text{Trace}(C')$) se mantiene. b) Muestre cómo el escalado (división por la desviación estándar) es esencial para PCA, demostrando qué sucede si una característica tiene varianza mucho mayor que otra.

- Use la propiedad $\text{Trace}(AB) = \text{Trace}(BA)$. Para (b), una explicación conceptual basada en (3) es suficiente.
- Use la ecuación (3)

Parte 2 – Prácticos en Papel (5 problemas)

Pregunta 1

Cálculo Básico de C y Proyección: Dado el conjunto de datos X (observaciones en filas):

$$X = \begin{pmatrix} 2 & 1 \\ 4 & 3 \\ 6 & 2 \end{pmatrix}$$

Objetivo: Calcular el vector de medias $\bar{\mathbf{x}}$, la matriz de datos centrados $\tilde{X}$ y la Matriz de Covarianza C (utilizar $M - 1$ en el divisor).

Pasos:

1. Calcular $\bar{\mathbf{x}}$.
2. Calcular $\tilde{X}$.
3. Usar Ecuación (1) para C .

Pregunta 2

Autovalores y Autovectores (2x2): Dada la matriz de covarianza:

$$C = \begin{pmatrix} 5 & 1 \\ 1 & 5 \end{pmatrix}$$

Objetivo: Hallar los autovalores λ_1, λ_2 y los autovectores unitarios $\mathbf{u}_1, \mathbf{u}_2$.

Pasos:

1. Resolver el polinomio característico $\det(C - \lambda I) = 0$.
2. Sustituir λ_i en $C\mathbf{u}_i = \lambda_i \mathbf{u}_i$ para encontrar $\mathbf{u}_i$.
3. Normalizar $\mathbf{u}_i$.

Pregunta 3

Proyección y Reconstrucción 3D $\rightarrow$ 2D: Utilice los resultados de P2 (autovectores/CP) para un conjunto de datos ya centrado, $\tilde{X}$. Proyecte el punto $\tilde{\mathbf{x}} = \begin{pmatrix} 2 \\ 1 \end{pmatrix}$ en el espacio 1D definido por el Primer Componente Principal $\mathbf{u}_1$. Luego, reconstruya el punto en el espacio original 2D y calcule el error de reconstrucción $\|\tilde{\mathbf{x}} - \hat{\mathbf{x}}\|_2^2$.

Pasos:

1. Usar $\mathbf{u}_1$ de P2.
2. Calcular el punto proyectado $\mathbf{z}_1 = \mathbf{u}_1^T \tilde{\mathbf{x}}$.
3. Reconstruir $\hat{\mathbf{x}} = \mathbf{z}_1 \mathbf{u}_1$.
4. Calcular el error.

Pregunta 4

Interpretación de Cargas (Loadings): Para una matriz de datos con 3 características centradas (X_A, X_B, X_C), el Primer Componente Principal es:

$$\mathbf{u}_1 \approx \begin{pmatrix} 0.8 \\ 0.5 \\ -0.3 \end{pmatrix}$$

Objetivo: Interpretar $\mathbf{u}_1$. ¿Qué combinación de variables originales explica este componente?

Pasos:

1. Analizar el signo y la magnitud de las cargas.
2. Redactar la interpretación.

Pregunta 5

Varianza Explicada Acumulada: Se ha calculado la matriz de covarianza de un conjunto de datos 4D, obteniendo los siguientes autovalores:

$$\lambda_1 = 12.0, \quad \lambda_2 = 3.5, \quad \lambda_3 = 0.8, \quad \lambda_4 = 0.3$$

Objetivo: a) Calcular la varianza explicada acumulada para $k = 1, 2, 3$. b) Determinar el número mínimo de componentes k necesario para retener al menos el **90%** de la varianza total.

Pasos:

1. Calcular la Varianza Total (Trace).
2. Usar la fórmula de la Varianza Explicada Acumulada para cada k .

Parte 3 – Programación en Python para Google Colab (2 problemas)

Pregunta 1

Aplicación y Visualización (PCA Clásico): Aplicar PCA sobre el dataset `load_wine`.

Preprocesar (estandarización), ajustar PCA y visualizar las dos primeras componentes principales. Generar el gráfico de varianza explicada acumulada y determinar k para el 95% de la varianza.

- **Librerías Sugeridas:** `numpy`, `pandas`, `sklearn.datasets`, `sklearn.preprocessing`, `sklearn.decomposition.PCA`, `matplotlib`.
- **Notas de Programación:** Implementar estandarización con `StandardScaler`. Generar un *scree plot* y una visualización 2D de los puntos transformados, coloreados por clase.

Pregunta 2

Escalado y Optimización (Randomized/Incremental PCA): Usar el dataset grande **MNIST-784** (70,000 imágenes, 784 características). Aplicar `PCA` con `svd_solver='randomized'` para reducir la dimensionalidad a $k = 50$. Medir el tiempo de ejecución. Calcular la calidad de la reducción (Varianza Explicada) y el error de reconstrucción (MSE) de una imagen.

- **Librerías Sugeridas:** `numpy`, `sklearn.datasets.fetch_openml`, `sklearn.preprocessing`, `sklearn.decomposition.PCA`, `time`.
 - **Notas de Programación:** Usar `float32` para ahorro de memoria. Comparar el tiempo de la solución rápida con la SVD completa (opcional, si es factible). Implementar la reconstrucción de una muestra: $\hat{\mathbf{x}} = \mathbf{z}V_k^T + \bar{\mathbf{x}}$.
-