


①



$$f(z) = \frac{1}{1 + e^{-z}}, \text{ f. activaci3n}$$

$$W^1 = \begin{pmatrix} w_{11} & w_{21} \\ w_{12} & w_{22} \end{pmatrix} = \begin{pmatrix} 0.5 & -1.0 \\ 0.8 & 0.2 \end{pmatrix}$$

$$b^1 = \begin{pmatrix} b_1 \\ b_2 \end{pmatrix} = \begin{pmatrix} 0.1 \\ -0.3 \end{pmatrix}$$

donde w_{ij} es el peso de la entrada x_i a la neurona j

$$W^2 = \begin{pmatrix} w_{11} \\ w_{21} \end{pmatrix} = \begin{pmatrix} 1.2 \\ -0.7 \end{pmatrix}$$

$$b^2 = (b_1) = (0.4)$$

Tarea: $X = \begin{pmatrix} 0.7 \\ 0.3 \end{pmatrix}$, calcule y_1 , realizar los c3lculos intermedios (entre netos z y activaciones a) para cada neurona.

Capa Oculta

$$I_{h_1} = x_1 w_{11} + x_2 w_{21} + b_1 = 0.35 - 0.3 + 0.1 = 0.15$$

$$\Rightarrow f(I_{h_1}) = \frac{1}{1 + e^{-0.15}} \approx 0.5374 = h_1$$

$$I_{h_2} = x_1 w_{12} + x_2 w_{22} = 0.56 + 0.06 - 0.3 = 0.32$$

$$\Rightarrow f(I_{h_2}) = \frac{1}{1 + e^{-0.32}} \approx 0.5793 = h_2$$

Capa Salida

$$I_{y_1} = h_1 w_{11}^{(2)} + h_2 w_{21}^{(2)} + b_1^{(2)} = 0.5374(1.2) + 0.5793(-0.7) + 0.4 \approx 0.6394$$

$$y_1 = f(z_{y_1}) = \frac{1}{1 + e^{-0.6394}} \approx 0.6546$$

② Demostración del descenso del gradiente.

El objetivo del D. gradiente es encontrar W que reduzca el error $E(W)$

$$\rightarrow W_{\text{nuevo}} = W_{\text{antigua}} + \Delta W$$

Usando expansión de Taylor de primer orden para $E(W + \Delta W)$ demostrar que:

$$\Delta W = -\eta \nabla E(W)$$

tenemos:

$$E(W + \Delta W) \approx \underbrace{E(W)}_{\text{error actual}} + \underbrace{\nabla E(W)^T \cdot \Delta W}_{\text{cambio a el error}}$$

$\nabla E(W)$: vector gradiente en el punto fijo

ΔW : vector de actualización

$$\begin{aligned} \text{Cambio} &= \nabla E(W)^T \cdot \Delta W \\ &= \|\nabla E(W)\| \|\Delta W\| \cos \theta \end{aligned}$$

Queremos que el resultado sea lo más negativo posible $\rightarrow \theta = 180$

Para obtener $\theta = 180$ entonces ΔW debe tener dirección contraria al gradiente $\nabla E(W)$

$$\therefore \Delta W = -\eta \nabla E(W)$$

③ Derivación de la regla de la cadena (Copa de salida)


$$E = \frac{1}{2} (y_{\text{deseado}} - y_{\text{actual}})^2$$

$y_{\text{actual}} = f(z_j)$ es la activación de una neurona de salida j

y $z_j = \sum_i w_{ij} h_i + b_j$, h_i es la activación de una neurona de la capa oculta i de la capa anterior

tarea: Usando regla de la cadena, derive la expresión para el gradiente del error con respecto a un peso de la capa de salida w_{ij} . Encuentre $\frac{\partial E}{\partial w_{ij}}$, descomponga lo derivado en tres partes claras

$$\left(\frac{\partial E}{\partial y_{\text{actual}}}, \frac{\partial y_{\text{actual}}}{\partial z_j}, \frac{\partial z_j}{\partial w_{ij}} \right)$$



→ Derivado del error respecto a la salida $\left(\frac{\partial E}{\partial y_{\text{actual}}} \right)$

$$E = \frac{1}{2} (y_{\text{des}} - y_{\text{act}})^2$$

$$\frac{\partial E}{\partial y_{\text{act}}} = (y_{\text{des}} - y_{\text{act}}) \left(\frac{\partial y_{\text{des}}}{\partial y_{\text{act}}} - \frac{\partial y_{\text{act}}}{\partial y_{\text{act}}} \right) = -(y_{\text{des}} - y_{\text{act}})$$

→ Derivado de la salida respecto a la entrada neta $\left(\frac{\partial y_{\text{act}}}{\partial z_j} \right)$

$$y_{\text{act}} = f(z_j)$$

$$\rightarrow \frac{\partial y_{oet}}{\partial z_j} = f'(z_j)$$

$\rightarrow$ Derivada de lo entrado neto respecto al peso $\left(\frac{\partial z_j}{\partial w_{ij}} \right)$

$$z_j = w_{j1}h_1 + w_{j2}h_2 + \dots + w_{jn}h_n + \dots + b_j$$

$$\frac{\partial z_j}{\partial w_{ij}} = h_i, \text{ es lo entrado que viene de la capa oculta.}$$

$$\rightarrow \frac{\partial E}{\partial w_{ij}} = -(y_{des} - y_{oet}) f'(z_j) \cdot h_i$$

$$S_j = (y_{des} - y_{oet}) f'(z_j) \quad \text{error} \times \text{derivada}$$

$$\rightarrow \frac{\partial E}{\partial w_{ij}} = -S_j h_i$$


(4) Derivación de la regla delta (Capa oculta)

Encontrar el gradiente para el peso w_{ki} que conecta la entrada x_k a una neurona oculta h_i . El error E depende de w_{ki} indirectamente a través de todos los neurones de la capa de salida o los que h_i esta conectada.

Tarea: derive la expresion para $\frac{\partial E}{\partial w_{ki}}$, demuestre como el gradiente

Depende de los pesos ponderados de los "Juntos" S_j

Sugerencia: $\frac{\partial E}{\partial w_{kp}} = \underbrace{\frac{\partial E}{\partial h_p}}_{\text{Parte A}} \underbrace{\frac{\partial h_p}{\partial z_p}}_{\text{Parte B}} \underbrace{\frac{\partial z_p}{\partial w_{kp}}}_{\text{Parte C}}$



→ Parte C

$$z_p = \sum x_k w_{kp} \rightarrow \frac{\partial z_p}{\partial w_{kp}} = x_k$$

→ Parte B

Suponemos: $h_p = f(z_p) \rightarrow \frac{\partial h_p}{\partial z_p} = f'(z_p)$

→ Parte A

El error total E es la suma de los errores a todos los neuronas de salida. La neurona oculta h_p depende a la salida $y=1, y=2, \text{ etc}$

$$\frac{\partial E}{\partial h_p} = \sum_j \left(\frac{\partial E}{\partial z_j} \cdot \frac{\partial z_j}{\partial h_p} \right)$$

Al problema anterior: $\frac{\partial E}{\partial z_p} = -S_p$

$$I_g = \sum_p h_p w_{pg} \rightarrow \frac{\partial I_g}{\partial h_i} = w_{ig}$$

$$\rightarrow \frac{\partial E}{\partial h_i} = \sum_g (-\delta_g \cdot w_{ig}) = -\sum_g \delta_g w_{ig}$$

Interpretación: La culpa de la neurona oculta es la suma ponderada de los culpos de las neuronas a las que alimenta.

$$\rightarrow \frac{\partial E}{\partial w_{kp}} = \left(-\sum_g \delta_g w_{ig} \right) f'(z_p) x_k$$

(5) $f(z) = \text{sigmoide}(z)$, $f'(z) = f(z)(1-f(z))$

Sea ahora $f(z)$ la tangente hiperbólica.

$$f(z) = \tanh(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}$$

tarea: Calcule $f'(z)$

Demostar qd se puede expresar en terminos de $f(z)$.

$$f(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}} \rightarrow \begin{aligned} u &= e^z - e^{-z} \\ v &= e^z + e^{-z} \end{aligned}$$

$$f'\left(\frac{u}{v}\right) = \frac{u'v - uv'}{v^2}$$

$$u' = e^z + e^{-z}, \quad v' = e^z - e^{-z}$$

$$\begin{aligned} f'(z) &= \frac{(e^z + e^{-z})(e^z + e^{-z}) - (e^z - e^{-z})(e^z - e^{-z})}{(e^z + e^{-z})^2} \\ &= \frac{(e^z + e^{-z})^2 - (e^z - e^{-z})^2}{(e^z + e^{-z})^2} = 1 - \left(\frac{e^z - e^{-z}}{e^z + e^{-z}} \right)^2 \\ &= 1 - f(z)^2 \end{aligned}$$

⑥ Retropropagación (Cálculo manual completo)



$$f(z) = \frac{1}{1 + e^{-z}}, \text{ f. activación}$$

$$f'(z) = f(z)(1 - f(z))$$

$$E = \frac{1}{2} (y_{des} - y_{act})^2$$

$$x_1 = 1.0$$

$$y_{des} = 0.5$$

$$w_1 = 0.4$$

$$w_2 = 0.8$$

$$b_1 = b_2 = 0$$

$$\eta = 0.1$$

Tarea: Realice una iteración completa del algoritmo de retropropagación.

1. Forward Pass (h_1 y y_1)

2. Cálculo error E

3. Backward pass (Deltas)

$$\delta_{y_1} = (y_{act} - y_{des}) f'(z_{y_1})$$

$$\delta_{h_1} = \delta_{y_1} \cdot w_2 \cdot f'(z_{h_1})$$

4. Actualización de los pesos

- Cálculo Δw_2 y el nuevo w_2

- " Δw_1 y el nuevo w_1

$$1) \quad z_{h_1} = x_1 w_1 + b_1 = 0.4 \rightarrow h_1 = \frac{1}{1 + e^{-0.4}} \approx 0.5987$$

$$z_{y_1} = h_1 w_2 + b_2 = (0.5987)(0.8) = 0.4789$$

$$\rightarrow y_1 = \frac{1}{1 + e^{-0.4789}} \approx 0.6175$$

$$2) \quad E = \frac{1}{2} (y_{\text{des}} - y_{\text{act}})^2 = \frac{1}{2} (0.5 - 0.6175)^2 \approx 0.0069$$

$$3) \quad \delta_{y_1} = (y_{\text{act}} - y_{\text{des}}) f'(z_{y_1})$$

$$\rightarrow f'(z_{y_1}) = f(z_{y_1})(1 - f(z_{y_1})) = y_1(1 - y_1) \\ = (0.6175)(1 - 0.6175) \approx 0.2362$$

$$\rightarrow \delta_{y_1} = (0.6175 - 0.5)(0.2362) \approx 0.02775$$

$$\delta_{h_1} = \delta_{y_1} \cdot w_2 \cdot f'(z_{h_1})$$

$$\rightarrow f'(z_{h_1}) = h_1(1 - h_1) = 0.5987(1 - 0.5987) \\ \approx 0.2402$$

$$\rightarrow \delta_{h_1} = (0.02775)(0.8)(0.2402) \\ \approx 0.00533$$

$$4) \quad \Delta w_2 = -\eta \delta y_1 = -0.1(0.02775) \\ \approx -0.00166$$

$$\rightarrow \text{New } w_2 : w_2 - 0.00166 \\ = 0.7983$$

$$\Delta w_1 = -\eta \delta h_1 = -0.1(0.00533) \\ \approx -0.000533$$

$$\rightarrow \text{New } w_1 : w_1 - 0.000533 \\ = 0.39947$$

Resultado: w_2 bajo de 0.8 a 0.7983

w_1 bajo de 0.4 a 0.3995

Ambos pesos disminuyeron debido a $\hat{y}$ estaban prediciendo muy alto la red (0.61) o comparado de o_s
 $\rightarrow$ Se necesita opagar un poco las conexiones.

⑦ Analisis de la regla delta Generalizado (Momentum)

$$\Delta w(n) = -\eta \underbrace{\frac{\partial E}{\partial w}}_{\text{gradiente actual}}(n) + \alpha \underbrace{\Delta w(n-1)}_{\text{Inercia (Momentum)}}$$

Tarea: Expandir la formula hacia el pasado hasta llegar al termino $n-3$.

Sea $G(n) = -\eta \frac{\partial E}{\partial W}(n)$

$\rightarrow \Delta W(n) = G(n) + \alpha \Delta W(n-1)$

sustituimos $(n-1)$, obtenemos: $\Delta W(n-1) = G(n-1) + \alpha \Delta W(n-2)$

$$\begin{aligned} \Delta W(n) &= G(n) + \alpha (G(n-1) + \alpha \Delta W(n-2)) \\ &= G(n) + \alpha G(n-1) + \alpha^2 \Delta W(n-2) \end{aligned}$$

sustituimos $(n-2)$, obtenemos: $\Delta W(n-2) = G(n-2) + \alpha \Delta W(n-3)$

$$\begin{aligned} \Delta W(n) &= G(n) + \alpha G(n-1) + \alpha^2 (G(n-2) + \alpha \Delta W(n-3)) \\ &= G(n) + \alpha G(n-1) + \alpha^2 G(n-2) + \alpha^3 \Delta W(n-3) \end{aligned}$$

Interpretación: el movimiento actual es la suma ponderada exponencial de todos los gradientes del pasado.

a) Ayuda a suavizar las oscilaciones cuando el gradiente cambia de signo? Si, el movimiento lateral se suava, permitiendo q la red se centre y baje por el valle del valle.

b) Ayuda a acelerar el descenso en regiones donde el gradiente es pequeño pero constante (cuasestacion)? Dato que acumulamos los gradientes del pasado esto es mucho mayor q η , permitiendo acelerar.

(8) Comparación de funciones de error (SSE vs Cross Entropy)

1. SSE: $E_{SSE} = \frac{1}{2} (y_d - \hat{y}_d)^2$

2. Cross Entropy (CE): $E_{CE} = -[y_d \ln(y_d) + (1 - y_d) \ln(1 - y_d)]$

donde: $y_a = f(z) = \text{siguante}(z)$

el bello de la cosa de solido es $S_g = \frac{SE}{\frac{\partial y_a}{\partial z}}$

area: 1. $\frac{\partial E_{SSE}}{\partial z}$, 2. $\frac{\partial E_{ce}}{\partial z}$

1. $E_{SSE} = \frac{1}{2} (y_d - y_a)^2$

$$\frac{\partial E}{\partial z} = \frac{\partial E}{\partial y_a} \cdot \frac{\partial y_a}{\partial z} \rightarrow \frac{\partial E}{\partial y_a} = (y_d - y_a) - 1 = -(y_d - y_a)$$

$$\frac{\partial y_a}{\partial z} = y_a (1 - y_a) \quad \text{p. Siguante}$$

$$\rightarrow \frac{\partial E}{\partial z} = -(y_d - y_a) \underbrace{(y_a)(1 - y_a)}_{\text{presenta un gran problema.}}$$

2. $E_{ce} = -[y_d \ln(y_d) + (1 - y_d) \ln(1 - y_d)]$

$$\frac{\partial E}{\partial z} = \frac{\partial E}{\partial y_a} \cdot \frac{\partial y_a}{\partial z} \rightarrow \frac{\partial E}{\partial y_a} = - \left[\frac{y_d}{y_a} - \frac{(1 - y_d)}{1 - y_a} \right]$$

$$= \frac{y_d - y_d}{y_a(1 - y_a)}$$

$$\rightarrow \frac{\partial y_a}{\partial z} = y_a(1 - y_a)$$

$$\rightarrow \frac{\partial E}{\partial z} = \frac{y_d - y_d}{y_a(1 - y_a)} \cdot y_a(1 - y_a) = y_d - y_d$$

Comparación: SSE : $(y_a - \hat{y}_a) f'(z)$, CE = $y_a - \hat{y}_a$
prob de ser de
error
desaparece el $f'(z)$, es DP
al error puro