



UNIVERSIDAD NACIONAL DE INGENIERÍA

Facultad de Ciencias

Escuela Profesional de Ciencias de la Computación

Examen Sustitutorio

Curso: Inteligencia Artificial (CC421)

Semestre 2025-I (14/07/2025)

Pregunta 1 (4 ptos.): Optimización de Ruta para Vehículos Autónomos con Búsqueda Informada

Una empresa de logística está desarrollando un sistema de vehículos autónomos para optimizar la entrega de paquetes en una ciudad. La ciudad puede ser modelada como un grafo donde los nodos son intersecciones y los aristas son calles con un costo asociado (tiempo de viaje). Para evitar congestiones y accidentes, el vehículo debe navegar desde un punto de inicio S hasta un destino D .

Objetivo: Desarrolle un pseudocódigo para un algoritmo de búsqueda **A** que permita al vehículo autónomo encontrar la ruta óptima. Considere que tiene acceso a una función heurística $h(n)$ que estima la distancia en línea recta (o euclidiana) desde cualquier nodo n hasta el destino D .

Consideraciones:

1. El grafo es no dirigido y los costos de los aristas son positivos.
2. El algoritmo debe mantener un registro del costo acumulado desde el inicio $g(n)$ y una estimación del costo total $f(n) = g(n) + h(n)$.
3. Debe manejar una cola de prioridad para explorar los nodos de manera eficiente.
4. Asuma que las estructuras de datos básicas (listas, diccionarios, colas de prioridad) están disponibles.

Pregunta 2 (6 ptos.): Descenso de Gradiente Estocástico con Momento y Regularización L2

Considere una red neuronal *feedforward* con una capa de entrada, una única capa oculta con H neuronas, y una capa de salida con K neuronas. Asuma que todas las neuronas usan la función de activación **ReLU** ($f(x) = \max(0, x)$) en las capas ocultas y de salida, excepto que la capa de salida final utiliza una función de activación **Softmax** para problemas de clasificación multiclase. La función de pérdida es la **entropía cruzada categórica**.

Dado un conjunto de datos de entrenamiento $\{(x^{(m)}, t^{(m)})\}_{m=1}^M$, donde $x^{(m)} \in \mathbb{R}^D$ es el vector de entrada y $t^{(m)} \in \{0, 1\}^K$ es el vector *one-hot* del objetivo para la m -ésima muestra.

La función de pérdida para una única muestra m es:

$$E^{(m)} = - \sum_{k=1}^K t_k^{(m)} \log(y_k^{(L,m)})$$

Donde $y_k^{(L,m)}$ es la activación de la k -ésima neurona de salida para la muestra m .

Se desea entrenar esta red utilizando **Descenso de Gradiente Estocástico (SGD)** con **momento** y **regularización L2 (weight decay)**.

a) Derivación de Backpropagation con ReLU y Softmax-CrossEntropy:

Deduzca las ecuaciones completas para las gradientes de los pesos y biases utilizando el algoritmo de backpropagation para esta arquitectura específica. Preste especial atención a la derivada de la función ReLU y a la combinación Softmax-CrossEntropy (demuestre que $\frac{\partial E^{(m)}}{\partial \text{net}_k^{(L,m)}} = y_k^{(L,m)} - t_k^{(m)}$).

b) Regla de Actualización con Momento y Regularización L2:

Formule las reglas de actualización para los pesos $W^{(l)}$ y biases $b^{(l)}$ de la red, incorporando los términos de **momento** y **regularización L2**. Sea η la tasa de aprendizaje, γ el coeficiente de momento y λ el coeficiente de regularización L2. Defina claramente todas las variables involucradas en sus ecuaciones de actualización.

Pregunta 3 (6 ptos.): RBM Profundas y Convoluciones Desconocidas

Considere dos desafíos avanzados en el aprendizaje profundo: la composición de modelos generativos y la implementación de una operación convolucional.

- a) **Entrenamiento de Máquinas de Boltzmann Restringidas Profundas (DBNs) y Limitaciones:** Usted tiene un conjunto de datos muy complejo y desea modelarlo utilizando una **Red de Creencia Profunda (DBN)** apilando múltiples RBMs. Explique en detalle el proceso de **entrenamiento no supervisado capa por capa (greedy layer-wise pre-training)** de una DBN utilizando RBMs. Destaque por qué este enfoque secuencial es crucial para el entrenamiento exitoso de redes profundas generativas y cómo mitiga los problemas que surgirían al intentar entrenar la DBN de forma monolítica con Contrastive Divergence global. Discuta las limitaciones inherentes a este proceso, especialmente en términos de la optimización del modelo generativo final.
- b) **Operación de Transposición Convolutiva (Deconvolución o Transposed Convolution):** Una operación clave en arquitecturas generativas como los autoencoders variacionales (VAEs) y las redes generativas adversarias (GANs) es la **Transposición Convolutiva** (a menudo incorrectamente llamada "deconvolución"). Dada una entrada de mapa de características de $H_{in} \times W_{in}$ y un filtro (kernel) de $K \times K$, con *stride* S y *padding* P , formule matemáticamente cómo se calcula la salida $H_{out} \times W_{out}$ de una operación de transposición convolutiva. Proporcione la relación entre H_{in}, W_{in}, K, S, P y H_{out}, W_{out} . Ilustre con un ejemplo numérico concreto (p.ej., entrada 2×2 , filtro 3×3 , stride 1, padding 0) mostrando cómo los elementos de la entrada contribuyen a la salida. Discuta brevemente por qué esta operación no es una "verdadera" deconvolución en el sentido matemático inverso, sino una convolución con un padding y stride específicos que emula un efecto de expansión.

Pregunta 4 (4 ptos.): Backpropagation en una Capa Convolutiva

Contexto: Una capa convolutiva aplica filtros $\mathbf{K} \in \mathbb{R}^{k \times k}$ a una imagen $\mathbf{X} \in \mathbb{R}^{n \times n}$, produciendo una feature map $\mathbf{Y} \in \mathbb{R}^{m \times m}$.

Tarea:

1. Derive el gradiente $\frac{\partial \mathcal{L}}{\partial \mathbf{K}}$ dado $\frac{\partial \mathcal{L}}{\partial \mathbf{Y}}$.
2. Demuestre que la operación equivale a una convolución transpuesta (deconvolución).
3. Compare el número de parámetros de una capa convolutiva vs. una densa para $n = 28, k = 5, m = 24$.

Ejemplo: Para $\mathbf{X} \in \mathbb{R}^{3 \times 3}$ y $\mathbf{K} \in \mathbb{R}^{2 \times 2}$, calcule $\frac{\partial \mathcal{L}}{\partial \mathbf{K}}$ dado $\frac{\partial \mathcal{L}}{\partial \mathbf{Y}} \in \mathbb{R}^{2 \times 2}$.
