



UNIVERSIDAD NACIONAL DE INGENIERÍA
Facultad de Ciencias
Escuela Profesional de Ciencias de la Computación

Examen Final

Curso: Inteligencia Artificial (CC421)

Semestre 2025-I

Parte I: Ejercicios de Pseudocódigo [10 puntos]

Ejercicio 1 (5 ptos.): Backpropagation en Perceptrón Multicapa

Contexto: En un sistema de diagnóstico de cáncer, un MLP clasifica tumores malignos (1) vs. benignos (0). Arquitectura:

- Entrada: 30 neuronas.
- Capas ocultas: 16 neuronas (ReLU) $\rightarrow$ 8 neuronas (ReLU).
- Salida: 1 neurona (sigmoide).

Tarea: Diseñe pseudocódigo para backpropagation con SGD considerando:

1. Función de pérdida: Entropía cruzada binaria.
2. Tasa de aprendizaje: $\eta = 0.01$.
3. Regularización L_2 : $\lambda = 0.001$.

4. Requisitos:

- a) Calcule $\frac{\partial \mathcal{L}}{\partial W_{out}}$ y $\frac{\partial \mathcal{L}}{\partial W_{h1}}$ explícitamente.
- b) Incluya el término de regularización en la actualización.

Ejercicio 2 (5 ptos.): Optimización de un Perceptrón Multicapa para Clasificación de Imágenes

Considere una red neuronal convolucional (CNN) simplificada que se utiliza para clasificar imágenes en dos categorías (C_0, C_1). Después de las capas convolucionales y de *pooling*, la salida se aplanar y se alimenta a un Perceptrón Multicapa (MLP) con una capa de entrada, una capa oculta y una capa de salida.

El MLP tiene las siguientes características:

- Capa de entrada: N neuronas (correspondientes a las características extraídas de la CNN).
- Capa oculta: H neuronas con función de activación ReLU ($f(x) = \max(0, x)$).
- Capa de salida: 1 neurona con función de activación sigmoide ($\sigma(x) = \frac{1}{1+e^{-x}}$) para la clasificación binaria.

El objetivo es implementar un algoritmo de entrenamiento para este MLP utilizando *backpropagation* y descenso de gradiente estocástico (SGD) con un término de regularización L_2 .

Tarea: Escriba el pseudocódigo para el algoritmo de entrenamiento del Perceptrón Multicapa, que debe incluir los siguientes pasos:

1. Inicialización de pesos y sesgos.

2. Bucle de entrenamiento (épocas y mini-batches).
3. Paso *forward*: Cálculo de las activaciones de la capa oculta y de salida.
4. Cálculo de la función de pérdida: Utilice la entropía cruzada binaria (L_{BCE}) más un término de regularización L2. La función de pérdida total es:

$$\mathcal{L}(\mathbf{w}, \mathbf{b}) = -\frac{1}{M} \sum_{i=1}^M [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)] + \frac{\lambda}{2} \sum_k w_k^2$$

donde M es el tamaño del mini-batch, y_i es la etiqueta real, $\hat{y}_i$ es la predicción del modelo, w son todos los pesos del MLP, y λ es el coeficiente de regularización L2.

5. Paso *backward* (Backpropagation): Cálculo de los gradientes de los pesos y sesgos con respecto a la función de pérdida. Asegúrese de incluir el gradiente del término de regularización.
6. Actualización de pesos y sesgos utilizando SGD con una tasa de aprendizaje α .

Supuestos:

- a) Las entradas del MLP ya han sido preprocesadas por las capas convolucionales.
- b) El tamaño del mini-batch es M .
- c) La tasa de aprendizaje α y el coeficiente de regularización λ son hiperparámetros dados.

Sección 2: Pregunta de desarrollo [10 puntos]

Ejercicio 3 (5 pts.): Derivadas para Backpropagation en Redes Convolucionales:

En una Red Neuronal Convolucional (CNN), la operación de convolución y la operación de *pooling* son fundamentales. Para aplicar el algoritmo de *backpropagation*, necesitamos calcular las derivadas de la función de pérdida con respecto a las entradas de estas capas.

Considere una capa convolucional 2D sin sesgo, donde la salida O_{ij} en la posición (i, j) se calcula como:

$$O_{ij} = \sum_{k=0}^{F-1} \sum_{l=0}^{F-1} I_{(i+k)(j+l)} \cdot K_{kl}$$

donde I es el mapa de características de entrada, K es el filtro (kernel) convolucional de tamaño $F \times F$, y se asume un *stride* de 1 y *padding* de 0.

Luego, considere una capa de *Max Pooling* con un tamaño de ventana $P \times P$ y un *stride* de S . La salida M_{ab} en la posición (a, b) es:

$$M_{ab} = \max_{p=0}^{P-1} \max_{q=0}^{P-1} O_{(aS+p)(bS+q)}$$

donde O es el mapa de características de entrada a la capa de *pooling*.

Tarea:

1. **Derivada de la convolución:** Sea L la función de pérdida. Demuestre cómo se propaga el gradiente $\frac{\partial L}{\partial O_{ij}}$ hacia la entrada de la capa convolucional. Es decir, encuentre la expresión para $\frac{\partial L}{\partial I_{kl}}$. (Sugiera el uso de la convolución transpuesta o la reorganización de la operación).
2. **Derivada de Max Pooling:** Demuestre cómo se propaga el gradiente $\frac{\partial L}{\partial M_{ab}}$ hacia la entrada de la capa de *Max Pooling*. Es decir, encuentre la expresión para $\frac{\partial L}{\partial O_{xy}}$. Explique dónde se debe colocar el gradiente.

Ejercicio 4 (5 ptos.): Relación entre Autoencoders y Boltzmann Machines Restringidas:

Un Autoencoder (AE) es una red neuronal no supervisada que aprende una representación compacta (codificación) de los datos de entrada, y luego intenta reconstruir la entrada a partir de esta representación. Una Boltzmann Machine Restringida (RBM) es un tipo de red neuronal estocástica con una capa visible y una capa oculta, sin conexiones intra-capas. Las RBMs son modelos generativos.

Considere un Autoencoder con una capa de entrada x , una capa oculta h y una capa de salida $\hat{x}$. Las transformaciones son:

$$h = \sigma(W_1 x + b_1)$$

$$\hat{x} = \sigma(W_2 h + b_2)$$

donde σ es la función sigmoide, W_1, W_2 son las matrices de pesos y b_1, b_2 son los sesgos.

Para una RBM, la energía del sistema para un estado (v, h) de las unidades visibles y ocultas es:

$$E(v, h) = -b^T v - c^T h - h^T W v$$

donde b y c son los sesgos de las unidades visibles y ocultas, respectivamente, y W es la matriz de pesos entre las capas visible y oculta.

Tarea:

Capa abstracta

Capa discreta

1. **Similitudes estructurales:** Explique las similitudes y diferencias estructurales entre un Autoencoder con una capa oculta y una Boltzmann Machine Restringida (RBM).

Encoder Espacio latente Decoder

2. **Relación funcional:** Demuestre y explique cómo el proceso de codificación de un Autoencoder (la parte del codificador) puede ser visto como equivalente a la probabilidad condicional $P(h|v)$ en una RBM, bajo ciertas condiciones y asunciones de activación y pesos. Específicamente, considere la activación de las unidades ocultas en la RBM:

$$P(h_j = 1|v) = \sigma \left(c_j + \sum_i W_{ij} v_i \right)$$

Relacione esta expresión con la operación del codificador del Autoencoder. Discuta las implicaciones de usar pesos ligados (tied weights) $W_2 = W_1^T$ en el Autoencoder en el contexto de las RBM.