



UNIVERSIDAD NACIONAL DE INGENIERÍA

Facultad de Ciencias
Escuela Profesional de Ciencia de la Computación

Examen Final

Curso: Inteligencia Artificial (CC421)

Semestre 2025-II (17/12/2025)

Instrucciones:

- Tiempo del examen 2.0 horas.
- Lea cuidadosamente cada pregunta antes de responder.
- Justifique todas sus respuestas con argumentos claros y concisos, haciendo referencia a los conceptos aprendidos en el curso.
- La claridad, el rigor conceptual y la profundidad del análisis serán valorados.

Pregunta 1. Demostración del Gradiente Local en Backpropagation (4.0 puntos)

Contexto: El algoritmo de retropropagación (*backpropagation*) utiliza el descenso por gradiente para minimizar el error total (E) de la red ajustando los pesos (W). El desafío es determinar la contribución (culpa o crédito) de un peso específico W_{JI} (que conecta la neurona I a la neurona J) al error total, conocido como el Problema de Asignación de Crédito.

Notación:

- E : Error total de la red.
- W_{JI} : Peso a ajustar (que conecta I a J).
- Y_I : Salida de la neurona I (entrada a la neurona J).
- V_J : Suma ponderada de las entradas de la neurona J , es decir, $V_J = \sum_I W_{JI} Y_I$.

Enunciado y Requerimientos de la Demostración:

1. **Aplicación de la Regla de la Cadena (1.5 puntos):** Formule la derivada parcial del Error total (E) con respecto al peso W_{JI} ($\frac{\partial E}{\partial W_{JI}}$) descomponiendo la dependencia ($E \rightarrow V_J \rightarrow W_{JI}$) mediante la Regla de la Cadena.
2. **Cálculo de la Dependencia Local (1.0 puntos):** Demuestre la derivada parcial de la entrada a la neurona J con respecto al peso ($\frac{\partial V_J}{\partial W_{JI}}$).
3. **Definición y Justificación del Gradiente Local (1.5 puntos):** Defina el término Δ_J (gradiente local) como aquel que encapsula la propagación del error en la neurona J . Explique por qué esta abstracción (Δ_J) es fundamental para la eficiencia del algoritmo, permitiendo que el cálculo sea local y que la neurona J sea responsable de asignar el crédito a todos sus pesos entrantes W_{JI} .

Pregunta 2. Análisis Estructural y Funcional de Arquitecturas Clave (4.0 puntos)

Análisis Comparativo de Arquitecturas de Redes Neuronales

Las arquitecturas de redes neuronales Multicapa (MLP), Autoencoders (AE), Redes Neuronales Convolucionales (CNN) y las Máquinas de Boltzmann Restringidas (RBM) representan hitos en la evolución del *Machine Learning*. Complete la siguiente tabla comparativa para diferenciar sus propiedades esenciales de forma concisa y justificada, basándose en la topología, el propósito y el mecanismo de ajuste de pesos.

Instrucciones: Rellene las celdas con la característica principal y añada una justificación breve pero precisa.

Característica	MLP (Perceptrón Multicapa)	Autoencoder (AE)	CNN (Red Convolutiva)	RBM (Máquina de Boltzmann Restringida)
a). Problema Principal Resuelto				
b). Tipo de Conectividad (Densidad)				
c). Uso de Compartición de Pesos (<i>Weight Sharing</i>)				
d). Mecanismo de Aprendizaje Principal				

Pregunta 3. Concepto Teórico sobre RBM y Autoencoders (5.0 puntos)

1. **RBM: Naturaleza y Objetivo Principal (1.0 punto)**

¿Qué tipo de red neuronal es una Máquina de Boltzmann Restringida (RBM) y cuál es su objetivo principal de aprendizaje, en términos de la distribución de probabilidad de los datos?

2. **RBM: Función de Energía (1.0 punto)**

Explique por qué las RBM se consideran modelos basados en energía y qué indica un valor escalar de energía bajo en el contexto de la configuración del modelo y la probabilidad.

3. **RBM: Algoritmo de Entrenamiento (1.0 punto)**

¿Cuál es el algoritmo más utilizado para entrenar las RBM y en qué se basa, a diferencia de la retropropagación utilizada en las redes *feedforward*?

4. **Autoencoders: Clasificación de Aprendizaje y Pérdida (1.0 punto)**

Aunque los Autoencoders se entrenan usando métodos de aprendizaje supervisado (como la retropropagación), dentro de qué categoría principal de aprendizaje se clasifican y por qué? Además, mencione las funciones de pérdida comunes utilizadas.

5. **Autoencoders Profundos y RBM (1.0 punto)**

Históricamente, ¿por qué fue difícil optimizar redes de Autoencoders no lineales con múltiples capas ocultas (Autoencoders profundos), y cómo utilizó Geoffrey Hinton las RBM para solucionar este problema y permitir el avance del *deep learning*?

Pregunta 4. Análisis Estructural y Gradiente en Redes Neuronales Convolucionales (7.0 puntos)

Enunciado: La Convolución como Solución a la Intratabilidad y el Desafío del Gradiente

El principal problema de las Redes Neuronales Multicapa (MLP) al procesar datos de alta dimensionalidad (como imágenes) era la **explosión paramétrica** debido a la conectividad densa, haciendo el entrenamiento intratable. Las Redes Neuronales Convolucionales (CNNs) resolvieron esto introduciendo la conectividad dispersa y la compartición de pesos. Sin embargo, la implementación del aprendizaje (*backpropagation*) en estas arquitecturas introduce nuevos desafíos teóricos relacionados con la topología profunda y los mecanismos de reducción dimensional (*pooling*).

Considere un escenario donde una capa de entrada de imagen I de tamaño 5×5 (1 canal) debe ser mapeada a un conjunto de mapas de características M de tamaño 3×3 . Se utilizan 10 filtros (*kernels*) de tamaño 3×3 .

$$C_{in} = 5, \\ W_{in} = 3 \times 3$$

$$K = 3,$$

Parte I: Demostración de la Eficiencia Paramétrica (3.0 puntos)

1. **Cálculo MLP (1.0 punto):** Calcule el número total de pesos ajustables que requeriría una capa MLP completamente conectada que reciba la entrada I (5×5) y genere una salida equivalente a los 10 mapas de características M (3×3 cada uno).
2. **Cálculo CNN (1.0 punto):** Calcule el número total de pesos ajustables que requiere la capa de convolución, utilizando 10 filtros de 3×3 y el principio de **compartición de pesos**.
3. **Justificación (1.0 punto):** Argumente por qué la CNN es fundamentalmente más adecuada que el MLP para el procesamiento de imágenes, basándose en la comparación de parámetros calculados.

Parte II: Profundidad y Reducción Dimensional (2.0 puntos)

1. **Función de Profundidad (1.0 punto):** Explique el concepto de las **capas cascada (convolution-pooling)** en las CNNs. ¿Cuál es la razón fundamental por la que la red requiere múltiples filtros (como 32, 64 o 128) y cómo esta *profundidad* ayuda a la red a pasar de la detección de características simples (ej. bordes) a características altamente complejas.
2. **Configuración de Pooling (1.0 punto):** Describa cómo la operación de *pooling* (Max Pooling) contribuye a que el modelo CNN sea más robusto a las pequeñas traslaciones o distorsiones de la entrada, y cómo esto se relaciona con la **reducción de la dimensionalidad** de las características extraídas.

Parte III: Retropropagación del Gradiente en la CNN (2.0 puntos)

La CNN utiliza el algoritmo de *Backpropagation* (Regla Delta Generalizada). Sin embargo, su aplicación difiere de la MLP debido a la estructura de pesos y las operaciones de reducción.

1. **Gradiente del Peso Compartido (1.0 punto):** Explique cómo se debe calcular el gradiente total del error ($\partial E / \partial W_{filter}$) para un único filtro de convolución (W_{filter}) que ha sido aplicado sobre *toda* la imagen (compartición de pesos). Argumente por qué este cálculo requiere una **suma** de los gradientes de error locales, a diferencia de la MLP donde el gradiente se calcula para cada peso de forma independiente.
2. **Gradiente a través de Pooling (1.0 punto):** Explique conceptualmente cómo se debe propagar hacia atrás el error a través de una capa de **Max Pooling** (muestreo descendente) para contribuir al gradiente de la capa de convolución anterior. ¿Qué impacto tiene la operación de Max Pooling en la ruta que toma el error al retroceder?