

Comparación de métodos de búsqueda local en la optimización de la función de Ackley

I. RESOLUCIÓN MATEMÁTICA PASO A PASO

1. DEFINICIÓN DEL PROBLEMA

La optimización de funciones matemáticas complejas es un área central en la Inteligencia Artificial. En esta parte, abordaremos la **función de Ackley**, una función de prueba estándar (benchmark) diseñada para evaluar algoritmos de optimización.

Definición Formal

En un espacio bidimensional, la función de Ackley se define matemáticamente como:

$$f(x, y) = -a \cdot \exp \left(-b \sqrt{\frac{1}{2}(x^2 + y^2)} \right) - \exp \left(\frac{1}{2}(\cos(cx) + \cos(cy)) \right) + a + \exp(1) \quad (1)$$

Donde los parámetros estándar son $a = 20$, $b = 0,2$ y $c = 2\pi$. Por lo tanto, la función se instancia como:

$$f(x, y) = -20 \cdot \exp \left(-0,2 \sqrt{0,5(x^2 + y^2)} \right) - \exp (0,5(\cos(2\pi x) + \cos(2\pi y))) + 20 + e \quad (2)$$

Características del Espacio de Búsqueda

- **Dominio:** Típicamente evaluada en el hipercubo $x, y \in [-32,768, 32,768]$. Para nuestras simulaciones analíticas, nos enfocaremos en un subespacio $[-5, 5]$.
- **Óptimo Global:** La función posee un único mínimo global en el origen, $\mathbf{x}^* = (0, 0)$, donde $f(0, 0) = 0$.
- **Múltiples Óptimos Locales:** El término cosenoidal introduce oscilaciones de alta frecuencia, creando una densa cuadrícula de valles (mínimos locales) y crestas (máximos locales).
- **Dificultad del Problema:** El paisaje de energía (energy landscape) se caracteriza por tener una estructura general de “embudo” (gobernada por el término exponencial de la distancia euclidiana) superpuesta con perturbaciones periódicas profundas. Esto engaña a los algoritmos basados puramente en gradiente o búsqueda local iterativa, ya que cualquier descenso codicioso caerá rápidamente en el “pozo” local más cercano y no podrá escalar las crestas para alcanzar el embudo principal.

Interpretación como Problema de Optimización

- **Estado:** Un vector $\mathbf{s} = (x, y) \in \mathbb{R}^2$.
- **Función Objetivo:** Minimizar $f(x, y)$.

2. HILL CLIMBING (ESCALADA)

Definición Formal

El algoritmo Hill Climbing (Ascenso de Colina, o Descenso de Gradiente en contextos de minimización) es una heurística de búsqueda local iterativa. Sea $\mathbf{s}_t$ el estado actual. El algoritmo define una vecindad $N(\mathbf{s}_t)$ y transiciona al mejor vecino estrictamente superior (o de menor costo).

$$\mathbf{s}_{t+1} = \arg \min_{\mathbf{s}' \in N(\mathbf{s}_t)} f(\mathbf{s}') \quad (3)$$

Si $f(\mathbf{s}_{t+1}) \geq f(\mathbf{s}_t)$, el algoritmo converge prematuramente.

Pseudocódigo Formal

Algoritmo: Hill Climbing

```
Algoritmo Hill_Climbing(f, s_inicial, paso Delta)
s_actual <- s_inicial
Mientras VERDADERO hacer:
  Vecinos <- Generar_Vecindad(s_actual, Delta)
  s_mejor <- argmin_{s' in Vecinos} f(s')
  Si f(s_mejor) >= f(s_actual) entonces:
    Retornar s_actual // Óptimo local o global alcanzado
  s_actual <- s_mejor
```

Simulación Paso a Paso

Parámetros: Paso $\Delta = 0,5$. Estado inicial $\mathbf{s}_0 = (1,5, 1,5)$.

Valores precalculados aproximados:

- $f(1,5, 1,5) \approx 7,93$ (Una cresta local)
- $f(1,0, 1,0) \approx 3,62$ (Un valle local adyacente)
- $f(2,0, 2,0) \approx 6,56$ (Otro valle local)
- $f(1,0, 1,5) \approx 6,12$

Tabla de Iteraciones:

Iteración	Estado $\mathbf{s}_t$	$f(\mathbf{s}_t)$	Mejores Vecinos Generados	Mejor Vecino $\mathbf{s}'$	$f(\mathbf{s}')$	Decisión
0	(1,5, 1,5)	7,93	(1,0, 1,5), (1,5, 1,0)	(1,0, 1,5)	6,12	Aceptar (Mejora)
1	(1,0, 1,5)	6,12	(1,0, 1,0), (0,5, 1,5)	(1,0, 1,0)	3,62	Aceptar (Mejora)
2	(1,0, 1,0)	3,62	(1,5, 1,0), (0,5, 1,0), (1,0, 0,5)	(1,0, 0,5)	5,31	Rechazar y Parar

Análisis del Fallo Matemático:

El algoritmo quedó atrapado en el estado (1,0, 1,0) con un valor de 3,62. Aunque el óptimo global está cerca (0,0), para llegar allí el algoritmo necesita atravesar las coordenadas intermedias

(ej. 0,5). La función cosenoidal impone que $\cos(2\pi(0,5)) = \cos(\pi) = -1$, lo cual maximiza la penalización en la función de Ackley creando una “pared de energía” de valor $\approx 5,31$. Hill Climbing carece del mecanismo estocástico para aceptar una solución temporalmente peor $\Delta f > 0$, atrapándose inexorablemente.

3. SIMULATED ANNEALING (RECOCIDO SIMULADO)

Definición Formal

Inspirado en la termodinámica de metales. Introduce una variable de control global T (temperatura) que decae en el tiempo. La variación de energía se define como $\Delta E = f(s') - f(s)$.

- Si $\Delta E < 0$, la solución mejora y es aceptada.
- Si $\Delta E \geq 0$, es aceptada con una **probabilidad de Boltzmann**:

$$P(\text{aceptar}) = \exp\left(-\frac{\Delta E}{T}\right) \quad (4)$$

A altas temperaturas T , el sistema exhibe alta entropía (comportamiento aleatorio), permitiendo escapar de mínimos locales. A bajas temperaturas, el sistema degenera en un simple Hill Climbing.

Pseudocódigo Formal

Algoritmo: Simulated Annealing

```

Algoritmo Simulated_Annealing(f, s_inicial, T_inicial, alpha, iter_max)
  s_actual <- s_inicial
  Mejor_s <- s_actual
  T <- T_inicial
  Para iter = 1 hasta iter_max hacer:
    s_vecino <- Generar_Vecino_Aleatorio(s_actual)
    Delta_E <- f(s_vecino) - f(s_actual)
    Si Delta_E < 0 o Aleatorio(0,1) < exp(-Delta_E / T) entonces:
      s_actual <- s_vecino
    Si f(s_actual) < f(Mejor_s) entonces Mejor_s <- s_actual
  T <- T * alpha
  Retornar Mejor_s

```

Simulación Paso a Paso (Mecanismo de Escape)

Supongamos que el algoritmo comienza atrapado en el óptimo local previo: $s = (1,0,1,0)$ con $f(s) = 3,62$.

$T_0 = 10,0$. $\alpha = 0,9$. Generación de vecino aleatorio.

Iter	s actual	s' vecino	f(s)	f(s')	ΔE	T	$P = \exp(-\frac{\Delta E}{T})$	Rand(0,1)	Decisión
1	(1,0,1,0)	(0,5,1,0)	3,62	5,31	+1,69	10,0	$\exp(-0,169) \approx 0,84$	0,45	Aceptado (Peor)
2	(0,5,1,0)	(0,0,1,0)	5,31	2,58	-2,73	9,0	$\exp(+0,30) > 1 \rightarrow 1,0$	0,12	Aceptado (Mejor)
3	(0,0,1,0)	(0,0,0,5)	2,58	4,41	+1,83	8,1	$\exp(-0,22) \approx 0,80$	0,62	Aceptado (Peor)
4	(0,0,0,5)	(0,0,0,0)	4,41	0,00	-4,41	7,29	1,0 (Mejora determ.)	0,33	Aceptado (Óptimo)

Análisis: Observen la iteración 1. El algoritmo saltó deliberadamente hacia la pared de energía $\Delta E > 0$, permitiéndole escalar y caer posteriormente en la cuenca de atracción del óptimo global (0,0,0,0).

4. ALGORITMOS GENÉTICOS (AG)

Definición Formal

Metaheurística poblacional basada en evolución estocástica.

- **Representación:** Individuo cromosómico $\mathbf{x}_i \in \mathbb{R}^2$.
- **Fitness:** Dado que buscamos minimizar $f(\mathbf{x})$, definimos el fitness (aptitud) a maximizar como $F(\mathbf{x}) = \frac{1}{1+f(\mathbf{x})}$.
- **Población:** $\mathcal{P}_t = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N\}$.
- **Selección:** Proceso estocástico sesgado hacia $F(\mathbf{x})$ elevado (ej. Ruleta o Torneo).
- **Cruce (Crossover):** Combinación convexa de padres: $\mathbf{x}_{hijo} = \beta \mathbf{x}_{padre1} + (1 - \beta) \mathbf{x}_{padre2}$.
- **Mutación:** Perturbación Gaussiana: $\mathbf{x}' = \mathbf{x} + \mathcal{N}(0, \sigma^2)$.

Pseudocódigo Formal

Algoritmo: Algoritmo Genético

```
Algoritmo AG(Tamaño_Pob, P_cruce, P_mutacion, Generaciones)
P_t <- Inicializar_Poblacion_Aleatoria(Tamaño_Pob)
Para gen = 1 hasta Generaciones hacer:
  Evaluar_Fitness(P_t)
  P_nueva <- Vacía
  Mientras Tamaño(P_nueva) < Tamaño_Pob hacer:
    padre1, padre2 <- Seleccion_Torneo(P_t)
    hijo1, hijo2 <- Cruzar(padre1, padre2, P_cruce)
    hijo1 <- Mutar(hijo1, P_mutacion)
    hijo2 <- Mutar(hijo2, P_mutacion)
    P_nueva.Agregar(hijo1, hijo2)
  P_t <- P_nueva
Retornar Mejor_Individuo(P_t)
```

Simulación Paso a Paso (1 Generación, Población N=4)

Población Inicial y Fitness:

1. $\mathbf{x}_1 = (1,0,1,0) \rightarrow f = 3,62 \rightarrow F = \frac{1}{1+3,62} = 0,216$
2. $\mathbf{x}_2 = (-1,0,1,0) \rightarrow f = 3,62 \rightarrow F = 0,216$
3. $\mathbf{x}_3 = (2,0,2,0) \rightarrow f = 6,56 \rightarrow F = 0,132$
4. $\mathbf{x}_4 = (0,5,-0,5) \rightarrow f = 6,40 \rightarrow F = 0,135$

Selección (Torneo de tamaño 2):

- Combate 1: $\mathbf{x}_1$ vs $\mathbf{x}_3 \rightarrow$ Gana $\mathbf{x}_1$
- Combate 2: $\mathbf{x}_2$ vs $\mathbf{x}_4 \rightarrow$ Gana $\mathbf{x}_2$

Cruce (Aritmético con $\beta = 0,5$):

Se cruzan $\mathbf{x}_1(1,0,1,0)$ y $\mathbf{x}_2(-1,0,1,0)$:

$$\mathbf{x}_{hijo1} = 0,5(1,0,1,0) + 0,5(-1,0,1,0) = (0,0,1,0)$$

Mutación (Ligera perturbación):

$$\mathbf{x}'_{hijo1} = (0,0,1,0) + \mathcal{N}(0,0,1) \rightarrow (0,05,0,95)$$

Evaluación del Nuevo Individuo:

$$f(0,05,0,95) \approx 2,70 \rightarrow F \approx 0,270 \text{ (¡Mejora estricta sobre los padres!)}$$

Análisis: La recombinación de coordenadas de dos óptimos locales simétricos guió la búsqueda directamente hacia la cuenca central del óptimo global, demostrando el poder del **Teorema de los Esquemas** adaptado a espacios continuos reales.

5. COMPARACIÓN FORMAL

Característica	Hill Climbing	Simulated Annealing	Algoritmos Genéticos
Tipo de Búsqueda	Un solo punto (Local)	Un solo punto (Estocástica)	Poblacional (Paralela)
Convergencia	Rápida, prematura	Lenta, garantizada a $T \rightarrow 0$	Moderada/Lenta, robusta
Calidad Solución	Pobre (Mínimo local)	Muy Alta (Mínimo global)	Muy Alta (Mínimo global)
Escape Óptimos Loc.	Ninguna	Probabilística (T)	Implícita (Cruce/Diversidad)
Complejidad Espacial	$\mathcal{O}(1)$	$\mathcal{O}(1)$	$\mathcal{O}(N)$ (donde N es pob.)

Explicación de Selección:

- Use **Hill Climbing** cuando se aplique Convexificación al problema o se requiera refinamiento rápido (fase de explotación).
- Use **Simulated Annealing** en espacios con alta dimensionalidad donde la paralelización no es crítica pero la memoria es limitada, y se requiere evadir pozos profundos.
- Use **Algoritmos Genéticos** en espacios de búsqueda vastos, altamente multimodales y rugosos (como Ackley en muchas dimensiones) donde explorar diferentes subespacios simultáneamente (fase de exploración) es mandatorio.

6. VISUALIZACIÓN CONCEPTUAL

El paisaje de Ackley es una estructura de embudo (funnel) con perturbaciones ondulatorias.

- La **Trayectoria del Hill Climbing** se dibuja como un segmento de recta corto que se estrella casi de inmediato contra el fondo de un “agujero” subóptimo de la cuadrícula ondulatoria.
- La **Trayectoria de Simulated Annealing** exhibe un recorrido de movimiento browniano (errático) en la periferia a altas temperaturas, estabilizándose gradualmente en oscilaciones más finas conforme se acerca al pozo del cero absoluto $\mathbf{x} = (0,0)$.

- La **Curva de Convergencia de AG** muestra una varianza altísima al principio (población esparcida). De pronto, múltiples hilos de la red de individuos convergen colapsando el enjambre estadístico sobre el pico central, evidenciado por el incremento exponencial de la aptitud promedio.

7. ERRORES COMUNES

- **En Hill Climbing:** Configurar un Δ demasiado pequeño causa que el algoritmo confunda mínimos planos con convergencia real. Un Δ demasiado grande produce oscilación sin convergencia.
- **En Simulated Annealing:** Seleccionar un factor de enfriamiento α muy pequeño (ej. 0,5). Esto “congela” (quenches) el sistema bruscamente, forzándolo a operar como un Hill Climbing antes de alcanzar equilibrio térmico.
- **En Algoritmos Genéticos:** Altas tasas de selección de los elites combinadas con bajas tasas de mutación. Esto induce la pérdida catastrófica de diversidad genética, colapsando la población en un óptimo local (endogamia algorítmica).

8. MICRO-EJERCICIOS Y PREGUNTAS TIPO EXAMEN

1. **Demostración Matemática:** Dado un incremento de energía $\Delta E = 2,5$, calcule la probabilidad de aceptación en SA cuando la temperatura actual es $T = 10$ y cuando $T = 1$. ¿Qué concluye sobre la probabilidad asintótica?
2. **Análisis Teórico:** Analice por qué en la función de Ackley, un cruce puramente aritmético de centroide $\mathbf{x}_c = 0,5\mathbf{x}_1 + 0,5\mathbf{x}_2$ entre individuos diametralmente opuestos es probabilísticamente muy ventajoso.