

UNIVERSIDAD NACIONAL DE INGENIERÍA
FACULTAD DE CIENCIAS - ESCUELA PROFESIONAL DE CIENCIA
DE LA COMPUTACIÓN

CURSO: Inteligencia Artificial CC421

TEMA: Análisis de Componentes Principales (PCA)

Práctica Dirigida

INSTRUCCIONES GENERALES

- La presente práctica debe ser resuelta estrictamente a mano (puede usar sus apuntes no buscar en internet). No se permite el uso de software de cálculo numérico o simbólico.
- Todo resultado debe estar rigurosamente justificado mediante demostración matemática o cálculo explícito.
- En los problemas de cálculo matricial, asuma que la matriz de covarianza muestral se define como $\Sigma = \frac{1}{n-1} X_c^T X_c$, a menos que se indique utilizar la versión poblacional ($\frac{1}{n}$).

BLOQUE 1: FUNDAMENTOS Y DEFINICIONES

Ejercicio 1: Definición y Redundancia

Considere un conjunto de datos $X \in \mathbb{R}^{n \times d}$. Defina formalmente el Análisis de Componentes Principales (PCA) desde la perspectiva de la maximización de la varianza. Explique por qué la presencia de alta covarianza entre las variables originales justifica la aplicación de PCA.

Ejercicio 2: El Requisito de Centrado

Sea una matriz de datos original X cuyas columnas no tienen media cero.

1. Demuestre algebraicamente por qué la matriz $\frac{1}{n-1} X^T X$ **no** es igual a la matriz de covarianza Σ .
2. Muestre cómo el cálculo matricial se simplifica cuando se utiliza la matriz centrada $X_c = X - \mu$, donde μ es el vector de medias.

Ejercicio 3: Propiedades de la Matriz de Covarianza

Sea $\Sigma = \frac{1}{n-1} X_c^T X_c$ la matriz de covarianza muestral. Demuestre formalmente dos propiedades fundamentales:

1. Σ es una matriz simétrica ($\Sigma^T = \Sigma$).
2. Σ es definida positiva o semidefinida positiva ($v^T \Sigma v \geq 0$ para todo $v \neq 0$).

Ejercicio 4: Ratio de Varianza Explicada

Asuma que, tras aplicar PCA a un dataset tridimensional, se obtienen los siguientes autovalores: $\lambda_1 = 4,5$, $\lambda_2 = 1,25$, $\lambda_3 = 0,25$.

1. Calcule el porcentaje de varianza explicada por cada componente.
2. Si el criterio del sistema es retener al menos el 95 % de la varianza total, ¿cuántos componentes principales deben seleccionarse? Muestre su cálculo.

BLOQUE 2: DEMOSTRACIONES MATEMÁTICAS

Ejercicio 5: Formulación del Problema de Optimización

Queremos encontrar una dirección (vector unitario) $w \in \mathbb{R}^d$ tal que la varianza de los datos proyectados sobre w sea máxima.

1. Demuestre que la varianza de la proyección $X_c w$ es proporcional a $w^T \Sigma w$.
2. Formule el Lagrangiano $\mathcal{L}(w, \lambda)$ para el problema de maximizar $w^T \Sigma w$ sujeto a la restricción euclidiana $\|w\|^2 = 1$.

Ejercicio 6: Derivación del Problema de Autovalores

Partiendo del Lagrangiano $\mathcal{L}(w, \lambda)$ construido en el Ejercicio 5:

1. Calcule el gradiente $\nabla_w \mathcal{L}(w, \lambda)$ y retrátelo paso a paso empleando cálculo matricial vectorial.
2. Igualando el gradiente a cero, derive rigurosamente la ecuación fundamental de PCA: $\Sigma w = \lambda w$.

Ejercicio 7: Varianza Máxima y Autovalores

Asumiendo que w_1 es una solución a la ecuación $\Sigma w_1 = \lambda_1 w_1$ con $\|w_1\| = 1$. Demuestre algebraicamente que la varianza de los datos proyectados sobre la dirección w_1 es exactamente igual al autovalor λ_1 . Concluya por qué el primer componente principal debe asociarse al autovalor más grande.

Ejercicio 8: Ortogonalidad de los Componentes Principales

Sean w_1 y w_2 dos autovectores de la matriz de covarianza Σ asociados a autovalores distintos $\lambda_1 \neq \lambda_2$. Aprovechando que Σ es simétrica, demuestre matemáticamente que w_1 y w_2 son ortogonales (es decir, $w_1^T w_2 = 0$).

BLOQUE 3: CÁLCULO MATRICIAL

Ejercicio 9: Operación de Centrado

Dado el siguiente conjunto de datos bidimensional con $n = 3$ muestras, representado en la matriz X :

$$X = \begin{pmatrix} 2 & 4 \\ 4 & 6 \\ 6 & 8 \end{pmatrix}$$

1. Calcule el vector de medias poblacional $\mu \in \mathbb{R}^2$.
2. Calcule la matriz de datos centrada X_c .

Ejercicio 10: Cálculo de Matriz de Covarianza

Utilizando la matriz centrada X_c obtenida en el Ejercicio 9:

1. Calcule explícitamente el producto matricial $X_c^T X_c$.
2. Determine la matriz de covarianza muestral $\Sigma = \frac{1}{n-1} X_c^T X_c$.

Ejercicio 11: Problema Espectral Básico

Suponga que para cierto conjunto de datos, la matriz de covarianza resultante es:

$$\Sigma = \begin{pmatrix} 5 & 4 \\ 4 & 5 \end{pmatrix}$$

1. Encuentre el polinomio característico $\det(\Sigma - \lambda I) = 0$.
2. Calcule los autovalores λ_1, λ_2 (ordénelos tal que $\lambda_1 \geq \lambda_2$).
3. Encuentre los autovectores normalizados w_1, w_2 asociados a cada autovalor.

Ejercicio 12: Proyección al Subespacio

Utilizando los resultados del Ejercicio 11:

1. Defina la matriz de proyección W_k para retener únicamente el primer componente principal ($k = 1$).
2. Proyecte el punto de datos original (ya centrado) $x_i = (1, 3)^T$ sobre este nuevo espacio unidimensional. Indique el valor escalar resultante.

Ejercicio 13: Reconstrucción de la Señal

1. Tome la proyección escalar obtenida en el Ejercicio 12 y aplique la transformación inversa para mapear el punto de vuelta al espacio original $\mathbb{R}^2$. Obtenga el punto reconstruido $\hat{x}_i$.
2. Calcule el error de reconstrucción (distancia euclidiana al cuadrado) $\|x_i - \hat{x}_i\|^2$.

BLOQUE 4: INTERPRETACIÓN GEOMÉTRICA

Ejercicio 14: Esferas y Elipsoides

Suponga que la matriz de covarianza de un dataset es la matriz identidad, $\Sigma = I$.

1. ¿Cuáles son los autovalores y autovectores?
2. Geométricamente, ¿qué forma tiene la nube de datos y por qué aplicar reducción de dimensionalidad mediante PCA en este caso específico sería un error conceptual?

Ejercicio 15: Sensibilidad a Valores Atípicos (Outliers)

Geoméricamente, PCA busca minimizar la distancia ortogonal de los puntos originales a la línea de proyección.

1. Explique mediante un diagrama esquemático (o descripción teórica detallada) cómo un único punto anómalo (outlier) masivamente alejado del centroide puede sesgar drásticamente la dirección del primer componente principal w_1 .

Ejercicio 16: Autovalores Nulos

Un ingeniero aplica PCA a un conjunto de datos tridimensional ($X \in \mathbb{R}^{100 \times 3}$) y obtiene los autovalores $\lambda_1 = 12,0$, $\lambda_2 = 3,5$, $\lambda_3 = 0,0$. Analice e interprete qué significa geoméricamente el hecho de que λ_3 sea exactamente cero respecto a la disposición espacial original de los 100 puntos en $\mathbb{R}^3$.

BLOQUE 5: APLICACIONES PRÁCTICAS

Ejercicio 17: El Sistema Masa-Resorte

Considere el experimento de una masa oscilando linealmente en un resorte unidimensional. Tres cámaras descalibradas graban la posición, generando un dataset $X \in \mathbb{R}^{n \times 3}$.

1. En un escenario ideal sin ruido, ¿cuál será el rango (rank) de la matriz de covarianza Σ ?
2. ¿Cuáles serán los valores esperados para λ_2 y λ_3 ?
3. Si introducimos un ruido gaussiano blanco pequeño en los sensores, ¿cómo cambiará el espectro de autovalores? Argumente físicamente.

Ejercicio 18: Redundancia Extrema

Se tiene un dataset de pacientes donde la columna 1 es el peso en kilogramos y la columna 2 es el peso exacto del mismo paciente en libras ($1 \text{ kg} \approx 2.2 \text{ lbs}$).

1. Calcule conceptualmente la correlación de Pearson entre ambas variables.
2. ¿Qué porcentaje de varianza explicada espera capturar el primer componente principal (PC1)? Justifique.

BLOQUE 6: ANÁLISIS CRÍTICO Y ERRORES

Ejercicio 19: Detección de Falla Metodológica

Planteamiento: Un estudiante de su clase afirma lo siguiente:

“Para aplicar PCA a una matriz de datos X que contiene mediciones de ingresos (en millones de dólares) y edad (en años), he realizado directamente la descomposición en valores singulares (SVD) de la matriz transpuesta $X^T X$, obteniendo los autovectores. He descartado el componente menor y he proyectado los datos.”

Tarea del estudiante:

Identifique y explique **DOS (2) errores metodológicos críticos** en el procedimiento del alumno. *Nota:* Aborde problemas tanto de preprocesamiento estadístico como de álgebra lineal, y proponga la corrección estructurada.

BLOQUE 7: EJERCICIO INTEGRADOR

Ejercicio 20: Pipeline Completo de PCA (Resolución manual)

Considere el siguiente conjunto de datos bidimensional $X \in \mathbb{R}^{3 \times 2}$ que representa el registro de 3 muestras:

$$X = \begin{pmatrix} -1 & -1 \\ 0 & 1 \\ 1 & 3 \end{pmatrix}$$

Desarrolle el pipeline completo de PCA estructurando su respuesta en los siguientes sub-pasos explícitos:

1. **Centrado:** Calcule μ y la matriz centrada X_c .
2. **Covarianza:** Calcule la matriz $\Sigma = \frac{1}{2} X_c^T X_c$.
3. **Descomposición:** Encuentre los autovalores λ_1, λ_2 de Σ .
4. **Bases Principales:** Encuentre los autovectores unitarios correspondientes w_1, w_2 .
5. **Reducción:** Elija el componente que maximiza la varianza (w_1) y proyecte el dato original $x_3 = (1, 3)^T$ sobre este espacio.
6. **Interpretación:** Basado en el valor de λ_2 calculado en el paso 3, concluya geoméricamente si los tres puntos de datos originales exhiben una relación perfectamente colineal en el espacio bidimensional. Justifique numéricamente.